



控制理论与应用

Control Theory & Applications

ISSN 1000-8152, CN 44-1240/TP

《控制理论与应用》网络首发论文

题目：基于群体嵌入的自适应最近邻欺诈检测方法
作者：蒋伟进，刘茜，聂彩燕，杨璇，杜熙晨
收稿日期：2025-05-15
网络首发日期：2026-01-08
引用格式：蒋伟进，刘茜，聂彩燕，杨璇，杜熙晨. 基于群体嵌入的自适应最近邻欺诈检测方法[J/OL]. 控制理论与应用.
<https://link.cnki.net/urlid/44.1240.TP.20260108.1256.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于群体嵌入的自适应最近邻欺诈检测方法

蒋伟进^{1,2}, 刘茜^{1,2†}, 聂彩燕^{1,2}, 杨璇^{2,3}, 杜熙晨^{1,2}

(1. 湖南工商大学 计算机学院, 湖南 长沙 410205;

2. 湘江实验室, 湖南 长沙 410205);

3. 湖南工商大学 人工智能与先进计算学院, 湖南 长沙 410205)

摘要: 针对金融欺诈检测中数据类别失衡、噪声敏感及欺诈模式关联稀疏的挑战, 本研究提出一种基于群体嵌入和自适应最近邻的欺诈检测方法。首先, 采用类别敏感性权重的改进随机欠采样技术, 动态调节良性类别和欺诈类别采样概率; 其次, 提出基于深度网络嵌入的网络表示学习算法, 生成低维鲁棒表示以捕捉欺诈行为时空演化特征; 最后, 构建融合自适应最近邻的随机森林框架, 引入非欧氏距离测度优化决策树分裂策略, 并利用潜在近邻投票机制整合局部与全局特征。实验结果表明, 该方法的AUC值较基准模型提升8%-16.72%, F_1 -score波动率低于1.8%, 验证了该方法在金融欺诈检测中的有效性。

关键词: 欺诈检测; 异常检测; 群体嵌入; 自适应潜在近邻

引用格式: 蒋伟进, 刘茜, 聂彩燕, 等. 基于群体嵌入的自适应最近邻欺诈检测方法. 控制理论与应用

DOI: 10.7641/CTA.2025.50206

An adaptive nearest neighbor fraud detection method based on clique embedding

JIANG Wei-jin^{1,2}, LIU Qian^{1,2†}, NIE Cai-yan^{1,2}, YANG Xuan^{2,3}, DU Xi-chen^{1,2}

(1. School of Computer Science, Hunan University of Technology and Business, Changsha 410205, China;

2. Xiangjiang Laboratory, Changsha 410205, China;

3. School of Artificial Intelligence and Advanced Computing, Hunan University of Technology and Business, Changsha 410205, China)

Abstract: To address the challenges of class imbalance, noise sensitivity, and sparse associations of fraud patterns in financial fraud detection, this study proposes a novel fraud detection method based on group embedding and adaptive nearest neighbors. First, it adopts an improved random undersampling technique with class-sensitive weights to dynamically adjust sampling probabilities of benign and fraudulent classes, mitigating imbalanced data impacts. Second, a deep network embedding-based representation learning algorithm generates low-dimensional robust representations, effectively capturing spatio-temporal evolutionary features of fraudulent behaviors. Finally, a random forest framework integrating adaptive nearest neighbors introduces non-Euclidean distance measures to optimize decision tree splitting strategies and utilizes a latent neighbor voting mechanism to synergistically integrate local and global features. Experiments on benchmark datasets show the method improves AUC values by 8% - 16.72% over state-of-the-art baselines, with F_1 -score volatility controlled below 1.8%, validating its efficiency, robustness, and practical applicability in real-world financial fraud detection.

Key words: Fraud detection; Anomaly detection; Clique embedding; Adaptive latent nearest neighbor

Citation: JIANG Weijin, LIU Qian, NIE Caiyan, et al. An adaptive nearest neighbor fraud detection method based on clique embedding. *Control Theory & Applications*

收稿日期: 2025-05-15; 录用日期: 2025-12-30.

†通信作者. E-mail: 726956360@qq.com.

本文责任编辑: 付俊

国家自然科学基金项目(61772196), 湖南省自然科学基金项目(2020JJ4249), 湖南工商大学研究生科研创新项目(CX2024YB008)资助。

Supported by the National Natural Science Foundation of China (61772196), the National Natural Science Foundation of Hunan Province (2020JJ4249) and the Postgraduate Research Innovation Project of Hunan University of Technology and Business(CX2024YB008).

1 引言

随着移动通信技术和大数据分析等信息技术的快速发展, 互联网金融服务应运而生, 深刻改变了传统金融行业的运作模式. 它通过提供便捷的在线支付、借贷、投资等服务, 极大地便利了人们的日常生活和商业活动. 然而, 金融欺诈行为也随之悄然兴起, 包括但不限于信用卡欺诈^[1]、抵押贷款欺诈^[2]、保险欺诈^[3]、财务报表欺诈^[4]、电子商务交易欺诈^[5]、大众营销欺诈^[6]、非法集资和洗钱^[7]等. 金融欺诈不仅给个人和企业带来直接的经济损失, 破坏了金融市场的公平性和信任基础, 还可能引发更广泛的社会经济问题, 对社会经济秩序造成严重威胁^[8].

鉴于金融诈骗手法的日新月异和环境愈发错综复杂, 迫切需要推动反欺诈技术向更高效率和更广泛适用性的方向演进^[9]. 通过深入分析用户行为和交易记录, 欺诈检测技术能够训练模型以辨识和预警可能的诈骗行为, 该技术在金融^[10]、医疗保健^[11]、通信^[12]、新闻报道^[13]以及评论监管^[14-15]等多个行业都得到了有效应用. 当前, 机器学习驱动的欺诈检测技术正逐渐成为网络支付安全防护的核心技术^[16]. 虽然机器学习能够自动从大量复杂的数据中学习并识别欺诈行为的模式, 提高欺诈检测的性能, 但仍然存在三个方面的不足:

1) 在执行数据采样过程中, 未能充分利用样本的标签数据, 这不仅导致采样后的数据未能实现类别间的平衡, 还可能遗失了至关重要的拓扑结构信息. 这种信息的缺失可能会降低目标节点在邻域信息聚合过程中的特征嵌入表现.

2) 噪声信息多以及标签的稀缺, 导致特征学习的指导信号弱, 由于大多数数据缺乏完备的标签, 噪声信息也会干扰模型的训练, 在标签稀缺和噪声信息充斥的双重影响下, 模型在捕捉良性与欺诈行为特征时的准确度受限, 进而导致了不够理想的检测表现.

3) 单一的分类器往往受限于其固有假设, 难以适应所有可能的数据分布, 尤其是在面对金融欺诈行为的多样性、复杂性和实时性时. 这些欺诈行为可能随着时间、技术、以及欺诈者策略的变化而不断演变, 使得模型在实际应用中面临严峻挑战.

本文针对金融领域的反欺诈问题, 提出一种基于群体嵌入和自适应最近邻的欺诈检测方法(Clique Embedding and Random Forest based Potential Nearest Neighbor, CE-PNN). 主要创新性如

下:

1) 针对金融欺诈数据类不平衡问题, 本研究摒弃了传统随机采样方法忽视拓扑结构信息的缺陷, 转而提出一种融合标签分布与节点拓扑重要性的采样机制. 首先依据数据集的欺诈率为欺诈类和良性类节点分配不同的采样权重, 权重设计使得少数类节点获得更高的采样概率. 其次, 引入节点的度作为调节因子, 高度节点因其可能蕴含更丰富的结构信息而被赋予更高的采样概率, 既缓解类别分布不均的问题, 又最大程度地保留了关键拓扑结构, 为后续自编码器进行有效的邻域信息聚合奠定了基础.

2) 针对动态网络拓扑实时更新效率低与噪声敏感的问题, 本研究提出了一种基于深度神经网络嵌入和储层采样的高效网络表示学习算法, 实现低维特征鲁棒性与计算效率的平衡. 一方面, 采用随机游走生成动态序列, 通过三元组损失约束强制编码器在潜在空间中保持团结构相似性, 降低重构误差, 并挖掘数据的低维结构; 另一方面, 构建顶点存储库动态维护邻居节点信息, 结合度分布概率更新游走序列, 较传统全量更新方法训练时间缩短、内存效率高, 满足金融场景实时、动态反欺诈需求.

3) 针对单一分类器动态适应性不足的问题, 本研究提出了一种融合自适应最近邻算法的随机森林分类框架, 与传统的随机森林模型相比, 该方法引入非欧氏单调距离测度重构决策树分裂规则, 根据数据的局部特性自适应地选择最优的特征和分裂点, 使特征选择动态适应局部数据分布. 同时, 考虑到袋外样本造成的信息丢失, 提出了一种新的基于潜在近邻的多决策树投票机制, 将决策树的局部划分空间转化为全局潜在邻居的动态投票池, 以取代传统的多数投票机制.

本研究第2节介绍自编码器(Contrastive Autoencoder, CAE)在降低特征维度方面的应用和互联网金融欺诈识别领域的相关研究进展; 第3节正式定义了金融网络中的异常检测问题; 第4节阐述了CE-PNN方法的实现细节; 第5节系统地描述了实验所用数据集和实验设置, 并对实验所得结果进行深入阐释和分析; 第6节对本研究工作进行概括.

2 相关工作

2.1 特征提取与降维

高维数据(如基因组信息、图像、视频和文本)的约简被视为生成高级数据表示的重要预处理步骤. 传

统的线性判别分析^[17-18](Linear Discriminant Analysis, LDA)和主成分分析^[19](Principal Component Analysis, PCA)方法倾向于通过单次特征提取, 执行特征空间变换, 将数据的高维特征集映射到一个具有更少自由度的特征子集, 而非逐步构建深层次的数据表示^[20]. 与之相对的自编码器利用人工神经网络最小化重构误差, 实现数据的压缩和降维. 因此, 自编码器及其衍生模型能够有效地提取出具有显著意义的特征.

Xu等^[21]提出了一种融合卷积自编码器网络与状态退化理论的滚动轴承寿命预测方法. 该方法首先通过CAE网络从退化轴承数据中自动提取特征, 紧接着构建状态退化模型, 采用多维健康状态映射函数对所提取的特征实行降维处理. 进一步地, 将降维后的数据点与欧氏距离相结合, 形成能够综合反映轴承健康状态的指标. Hu等^[22]利用自编码器模型重构原始输入数据, 在一定程度上起到去噪的作用. 同时, CAE包含正向特征提取网络和负向特征提取网络, 这两个网络通过自编码器结构来自动学习输入数据的特征表示, 从而增强特征提取的鲁棒性. Li等^[23]提出了一种基于记忆增强时间卷积自编码器的无监督异常检测方法. 基于扩展因果卷积、跳跃连接和自编码器构建了一种新的时间卷积自编码器模型, 便于模型学习输入数据的时间特征, 从而增强模型捕捉数据复杂结构的能力. Huleihel等^[24]基于卷积自编码器通过编码器和解码器表示网络, 在两者之间, 学习的潜在表示通过物理通信通道.

综上, 自编码器及其衍生模型在高维数据降维和特征提取方面具有强大的应用潜力, 但上述方法在特征提取方面仍然存在不足, 尤其是在处理动态数据和复杂非线性关系时. 通过动态网络嵌入和深度自编码器的结合, 可以更好地提升特征提取的灵活性和鲁棒性, 适应多样化的应用场景.

2.2 欺诈检测

在互联网金融反欺诈领域, 欺诈检测技术已经从传统的名单筛选和规则匹配, 逐步演进为采用机器学习算法来构建更为精准的欺诈检测模型^[9]. 依据训练数据的标签情况, 现有工作可以归纳为三个类别: 基于监督学习、基于无监督学习和基于半监督学习^[25]的欺诈检测. 当模型基于已标记的金融交易数据进行训练时, 本文称之为监督学习. 如果训练过程中完全没有使用标记数据, 则为无监督学习. 而半监督

学习则是在少量标记数据和大量未标记数据的辅助下进行的. 除此之外, 欺诈检测领域还涌现出多种以学习范式创新或数据利用方式扩展为核心的技术路径, 例如联邦学习、迁移学习、强化学习和基于图的欺诈检测等.

2.2.1 基于数据标签分类的欺诈检测

监督学习模型的一个显著优点是其预测结果通常具有较高的可解释性, 但受限于完整标签数据集的获取难度和高昂的成本, 且在面对模糊数据和新出现的欺诈模式时, 其识别能力有限. Jiang等^[26]认为欺诈行为可以在一个同时考虑连续和交互行为的时间二部网络中表现出来, 并提出了一种新的Hawkes增强序列模型, 从相邻序列中学习序列模式, 用于欺诈检测. 其通过设计一个考虑长期历史影响的衰减门, 将Hawkes过程整合到传统长短期记忆网络(Long Short-Term Memory, LSTM)的神经单元中, 并建立了一个考虑重复模式的历史注意机制. 需要注意的是, 一旦输入序列的长度超出某个阈值, LSTM网络的性能和效率便会显著降低. LSTM的改进措施包括并行处理和简化网络结构等等. 门控循环单元(Gated Recurrent Unit, GRU)网络便是一个通过减少单元内部门的数量来提高效率的变体. Forough等^[27]通过结合LSTM和GRU模型, 并运用深度学习模型的集成投票机制, 成功提升了欺诈检测集成模型的整体表现. 李康和等^[28]开发了一种图神经网络欺诈检测技术, 其特点是对背景噪声的高效过滤和对关键特征的显著增强. 该方法通过定制的相似度度量函数来量化节点间的关联性, 并运用强化学习算法优化噪声过滤参数. 此外, 通过构建欺诈样本间的连接, 该方法能够丰富网络的拓扑结构, 进而增强对欺诈特征的嵌入表达, 提升检测的准确性.

无监督学习和半监督学习在处理动态增长的数据集、尤其是在金融欺诈检测领域中, 提供了有效的解决方案. 通过这些方法, 可以在不断变化的数据环境中实时检测和适应新的欺诈模式, 而不需要重新训练整个模型, 从而显著降低了处理时间和内存使用. Zhao等^[29]提出了一种基于高斯混合模型的增量聚类方法, 用于在飞行数据中检测异常, 这种方法能够适应动态增长的数据, 并且通过期望最大化算法(Expectation-Maximization, EM)不断适应新的数据点, 从而避免了传统离线学习方法在处理新数据时需要重新训练模型的高时间和内存消耗问题.

Lucas等^[30]通过运用多视角隐马尔可夫模型(Hidden Markov Model, HMM), 结合自动化的特征工程技术来捕捉信用卡交易的时间序列相关性, 并辅以专家制定的信用卡欺诈特征工程策略, 从而增强了模型的分类准确性. 无监督学习通过分析数据内在的结构和模式, 为金融欺诈检测提供了一种有效的手段. 然而, 当引入少量的标记数据时, 半监督学习能够进一步提升模型的性能, 其介于传统监督学习和无监督学习之间, 通过结合有标签和无标签的数据提高了学习效率和模型的泛化能力. Aftabi等^[31]利用生成式对抗网络生成易受欺诈影响的合成样本, 克服易欺诈样本的缺乏. 通过使用相关矩阵和采用无监督模型, 降低特征空间的高维数, 并提供丰富的数据表示. Akinyelu等^[32]采用蚁群优化实例选择算法(Ant Colony Optimization Instance Selection Algorithm, ACOISA)来优化支持向量机(Support Vector Machine, SVM)的处理速度. 该研究利用ACOISA进行边界检测, 并通过K最近邻(K-Nearest Neighbors, KNN)算法来选择边界实例, 在提高SVM训练速度的同时保持损失分类质量.

2.2.2 基于学习范式分类的欺诈检测

随着金融欺诈手段的复杂化, 传统监督学习范式在数据隐私、模型泛化与动态适应性层面的局限性日益凸显. 在此背景下, 分布式模型训练范式革新与多源异构数据治理范式转型成为突破金融行业瓶颈的核心驱动力. 针对信用卡欺诈检测中数据孤岛、静态特征局限性及跨机构欺诈关联缺失的挑战, Tang等^[33]提出基于联邦图学习(Federated Graph Learning, FGL)的欺诈检测模型, 通过隐私保护的分布式图神经网络建模交易关联, 结合图扩展算法——CFG网络填补跨机构欺诈链路, 并采用自适应余弦相似度聚合权重, 显著提升模型对隐蔽欺诈行为的识别能力. 于浩淼等^[34]通过随机游走特征增强和子核分解, 挖掘多关系图中的节点层级和全局网络层级的拓扑信息, 优化了图结构特征的传播与聚合. 针对在线广告欺诈面临的概念漂移、数据孤岛和静态特征局限性问题, Sisodia等^[35]提出了一种基于深度卷积神经网络的迁移学习框架. 结合t分布随机邻域嵌入(t-distributed Stochastic Neighbor Embedding, t-SNE)降维与凸包算法, 将非图像的用户点击数据转换为二维图像, 并其从二维图像中区分欺诈或非欺诈.

综上所述, 互联网金融反欺诈技术呈现从依赖专家规则向机器学习转变的架构演进, 以及从小规模数

据处理向大规模数据分析的计算发展. 机器学习算法的跨领域应用和多技术融合正朝着更深层次的智能化方向发展.

3 问题定义

给定一个随时间变化的网络 $G(t) = (\epsilon(t), V(t))$, 我们假设在时间戳 t 时, 网络对象的输入流通常是一小部分网络对象, 用边集 $E^{(t)}$ 表示, 其中 $|E^{(t)}| \geq 1$. 在时间戳 t 时边集 $E^{(t)}$ 中的所有顶点用 $V^{(t)}$ 表示. 顶点集 $V(t)$ 表示从1到 t 的所有时间戳的顶点集的并集, 即 $V(t) = \cup\{V(t')\}_{t'=1}^t$. 同理, 我们有 $\epsilon(t) = \cup\{E(t')\}_{t'=1}^t$. 需要注意的是, 在时间戳 t 时, 顶点的完整集合可能是未知的, 因为对于任何时间戳 $t' > t$, 新的顶点可能会在任何时间戳 t' 持续到达. 网络 $G(t)$ 包括从时间戳1到 t 接收的所有边.

我们的目标是在任何给定的时间戳 t , 即在边集 $E_{(t)}$ 发生时实时检测异常的顶点、边和顶点集. 为了实现这一目标, 我们将网络 $G(t)$ 编码为一个特征矩阵, 其中每一行代表一个顶点的向量表示. 主要挑战包括:

- 1) 需要一种内聚的方式来编码动态网络;
- 2) 传入的网络对象应该很容易地用学习到的网络表示进行编码;
- 3) 网络表示需要新的网络对象到达时高效地更新.

应对上述挑战的一个关键前提是保持网络拓扑结构完整性(Network Topological Integrity). 其定义如下:

定义 1 网络拓扑结构完整性. 在动态网络演化过程中, 网络的基本结构属性在时间上保持相对稳定, 且新增或删除的边与顶点符合网络原有的演化规律, 不会导致结构特征的显著偏离. 若网络在某一时刻出现结构性异常, 如突然出现高度孤立的顶点、异常密集或稀疏的子图、跨社区的非典型连接等, 则称该时刻的网络拓扑结构完整性受到破坏.

本文采用基于自适应最近邻的随机森林方法来检测动态网络中的异常. 在计算嵌入顶点之间的距离后生成决策树. 传入的网络对象是否异常, 可以从它们各自的表示与现有集群之间的距离来确定. 当新的网络对象到达时, 检测结果可以高效更新. 本文使用的符号总结于表1.

表 1 符号说明

Table 1 Symbol explanation

符号	说明
α	比较标记和未标记样本的平均路径长度的阈值
β	测量未标记样品的正面和负面影响之间差异的阈值
$\mathcal{E}(t)$	从时间戳1到 t 接收的流式边
$\mathcal{V}(t)$	跨越时间戳1到时间戳 t 的顶点集
$G(t)$	用 $\mathcal{E}(t)$ 和 $\mathcal{V}(t)$ 表示的时间戳 t 时的网络
$\Omega(t)$	$G(t)$ 的一组网络游走集
m	顶点数, $ \mathcal{V}(t) $
n	边数, $ \mathcal{E}(t) $
l	游走长度
ψ	每个顶点的网络游走数
$ \Omega $	网络游走总数, $ \Omega = n \times \psi$
d	顶点表示的潜在维数
ρ	稀疏度参数
n_l	自编码器网络的总层数
$\mathbf{x}_p^{(i)} \in \mathbb{R}^n$	第 $i \in [1, \Omega]$ 次网络游走中的第 $p \in [1, l]$ 个顶点的输入向量
$\mathbf{W}^{(\ell)} \in \mathbb{R}^{n \times d}$	第 ℓ 层的权重矩阵
$\mathbf{b}^{(\ell)} \in \mathbb{R}^d$	第 ℓ 层的偏置向量
$\mathbf{D} \in \mathbb{R}^{n \times n}$	对角度矩阵
$f^{(l)}(x)$	第 ℓ 层的网络输出

4 CE-PNN方法

CE-PNN方法的总体架构如图1所示, 该架构主要由四大核心组件构成: 第一, 平衡采样单元. 通过欺诈率驱动的动态权重机制, 基于欺诈率赋予欺诈节点高权重和良性节点低权重, 并结合邻居数量保护拓扑结构, 生成均衡的训练子图, 为后续特征工程单元供均衡且结构完整的输入. 第二, 特征工程单元. 通过深度神经网络嵌入自主学习数据的复杂结构和模式; 当网络结构发生变化时, 通过储层采样快速更新节点的顶点库存储和网络游走序列, 从而动态调整网络表示. 特征工程单元为集成学习单元提供了高质量的低维特征表示, 这些特征表示能够更好地捕捉数据的拓扑结构和属性信息, 从而提高随机森林的分类性能. 第三, 集成学习单元. 基于上述分类特征, 该组件构建基于自适应最近邻优化的随机森林分类框架, 引入非欧氏单调距离测度重构决策树分裂规则, 根据数据的局部特性自适应地选择最优的特征和分裂点, 使特征选择动态适应局部数据分布, 从而为决策制定单元提供

更准确的潜在最近邻信息. 最后, 采用基于潜在近邻的多决策树投票机制, 将决策树的局部划分空间转化为全局潜在邻居的动态投票池, 进行最终的欺诈检测和风险评估.




图 1 CE-PNN总体架构图

Fig. 1 Overall architecture diagram of CE-PNN

4.1 标签平衡采样

在金融欺诈检测相关业务中, 交易行为数据量巨大, 且合法交易行为数量远远多于欺诈行为, 这使得预测结果更倾向于有效事务, 并增加了合法样本错误分类的风险. 为了避免这种情况, 本文采用改进的加权随机欠采样(Weighted Random Under-Sampling, W-RUS)对数据集进行预处理, 提升少数类的实例, 以保持数据集的两个主要类别之间的正常平衡.

本文构建了一个包含多重关系的无向图 $G = \{V, R, E, A, X, Y\}$, 其中, $V = \{v_1, v_2, \dots, v_n\}$ 为 G 中的 n 个节点构成的集合; 关系集合 $R = \{r_1, r_2, \dots, r_\delta\}$ 包含 δ 种不同关系; $E = \{\varepsilon_{r1}, \varepsilon_{r2}, \dots, \varepsilon_{r\delta}\}$ 表示 G 中所有边构成的集合, 而 $\varepsilon_{ri} (1 \leq i \leq \delta)$ 表示关系 r_i 对应边的集合; A 是节点的邻接矩阵, 针对关系集合 R 中的不同关系, 对应的邻接矩阵表示为 $A_{ri} \in \{A_{r1}, A_{r2}, \dots, A_{r\delta}\} (1 \leq i \leq \delta)$; $X = \{x_1, x_2, \dots, x_n\}$ 表示 V 中节点的特征集合, 每个节点 $v_j (1 \leq j \leq n)$ 有一个 m 维的特征向量 $x_j \in X$,

Y 表示为 V 中节点的标签集合. 针对图中的任意节点 $v \in V$, 根据其标签类型, 为其定义了相应的采样权重, 具体定义方式如下:

$$f_v = \begin{cases} |V|, & v \in \text{欺诈类} \\ a \cdot \frac{|V|}{\gamma}, & v \in \text{良性类} \end{cases} \quad (1)$$

其中, $|V|$ 为 V 中的节点总数, 表示样本中的欺诈发生率, a 为超参数. 随着节点 v 在集合 V 中的采样权重 f_v 的提升, 其被选中进行采样的可能性相应降低. 这种权重配置方法使我们能够基于数据集中欺诈行为的发生率, 对欺诈性节点与正常节点的采样频率进行调整. 此外, 考虑到节点 v 的一阶邻居数目, 本文对其最终的采样概率进行了如下定义:

$$p_v = \frac{\sum_{i=1}^{|V|} A_{ij}}{f_v} = \frac{H_{jj}}{f_v}. \quad (2)$$

其中, j 为节点 v 在邻接矩阵 A 中对应的索引位置, 矩阵 H 为 A 对应的度矩阵, 节点 v 的一阶邻居的计数可以通过对矩阵 A 中第 j 行的元素求和得到, 即求和公式 $\sum_{i=1}^{|V|} A_{ij}$. 同样, H 矩阵的第 jj 项 H_{jj} 也提供了这一信息. 根据公式(2)的推导结果, 可以得知, 节点 v 的采样概率与其一阶邻居的数量成正比, 同时与其采样权重 f_v 成反比. 这种设计有助于在采样过程中增加少数类别节点的代表性, 确保采样后的数据集在标签分布上更为均衡.

4.2 基于编码网络流的特征提取工程

为了实时检测动态网络中的异常, CE-PNN方法需要随着网络的演化高效学习网络表示并进行在线更新. 为简化讨论, 本节仅考虑未加权网络中新增边的情况. 处理减少边或处理加权网络的情况将在第4.2.2节中详细讨论. 本节将介绍CE-PNN方法中网络表示学习和更新机制, 该过程无需存储整个网络结构.

4.2.1 网络游走生成

类似于在构建词向量表示时采用的词嵌入技术^[36-37], 本文将网络分解成一组网络游走, 每个网络游走包含了由随机游走选择的一系列顶点. 本文对网络游走的定义如下:

定义 2 网络游走(Network Walk, NW). 对于给定网络 $G(\mathcal{E}, \mathcal{V})$ 中的顶点 $v_1 \in \mathcal{V}$, 其网络游走集合定义为 $\Omega_{v_1} = \{(v_1, v_2, \dots, v_l) \mid (v_i, v_{i+1}) \in \mathcal{E} \wedge p(v_i, v_{i+1}) = \frac{1}{D_{v_i, v_i}}\}$, 这是一系列从顶点 v_1 开始的 l 跳游走的集合. 从顶点 v_i 到 v_{i+1} 的转移概率 $p(v_i, v_{i+1})$ 与顶点 v_i 的度数 D_{v_i, v_i} 成正比. 我们

称 Ω_v 为从顶点 v 开始的网络游走集合, 而 $\Omega = \{\Omega_v\}_{v \in \mathcal{V}}$ 为所有游走的并集.

与自然语言中通常遵循幂律分布的单词频率类似, 我们观察到, 如果网络的度分布遵循幂律分布, 则网络行走中出现的顶点的频率分布也遵循幂律分布(或Zipf定律)^[38]. 因此, 我们将使用网络游走流作为我们从网络中提取信息的基本工具. 然后, 我们使用4.2.2节中介绍的一种新的嵌入方法来学习网络的顶点表示.

4.2.2 网络游走生成

在网络表示学习阶段, CE-PNN将标签均衡化后的初始网络作为输入, 并为每个顶点学习潜在表示. 我们将网络表示学习问题表述为一个优化问题. 我们的目标是学习一个映射函数 $f: \mathcal{V} \rightarrow \mathbb{R}^d$, 使得每个 $v \in \mathcal{V}$ 表示为一个 d 维向量, 其中 d 为潜在空间维数. 映射函数 f 适用于任何有向或无向、带权或不带权的网络. 值得注意的是, 在我们方法学习到的向量表示空间中可以找到线性可分的簇.

受skip-gram架构^[34]的启发, 我们提出了一种网络嵌入算法——群体嵌入算法(Clique Embedding, CE), 该算法利用深度自编码器神经网络通过网络游走流学习顶点的向量表示, 同时最小化每个游走中所有顶点之间的成对距离. 输入和输出都是独热编码向量, 即对于给定的顶点输入 $\mathbf{x}_p^{(i)} \in \mathbb{R}^n$, 只有 n 个元素中的一个为1, 其余均为0. 我们的目标是为每个输入网络游走 $\{\mathbf{x}_p^{(i)}\}_{p=1}^l$ 学习潜在表示. 其中, l 是游走长度, $\{W^{(\ell)}\}_{\ell=1}^{n_l}$ 是权重矩阵, $\{b^{(\ell)}\}_{\ell=1}^{n_l}$ 是偏置向量, $f^{(\ell)}(\cdot)$ 表示每一层的输出.

形式上, 给定一个独热编码的网络游走序列 $\{\mathbf{x}_p^{(i)}\}_{p=1}^l, i = 1, \dots, |\Omega|$, 我们希望在 n_l 层自编码器网络中学习以下表示:

$$f^{(\frac{n_l}{2})}(\mathbf{x}_p^{(i)}) = \sigma \left(W^{(\frac{n_l}{2})\top} h^{(\frac{n_l}{2})}(\mathbf{x}_p^{(i)}) + b^{(\frac{n_l}{2})} \right). \quad (3)$$

其中

$$h^{(\frac{n_l}{2})}(\mathbf{x}_p^{(i)}) = W^{(\frac{n_l}{2}-1)} f^{(\frac{n_l}{2}-1)}(\mathbf{x}_p^{(i)}) + b^{(\frac{n_l}{2}-1)}. \quad (4)$$

$n_l \geq 2; f^{(0)}(\mathbf{x}_p^{(i)}) = \mathbf{x}_p^{(i)}; \sigma(z) = \frac{1}{1+\exp(-z)}$ 为sigmoid函数. 在自编码器网络中, 输出假设 $f^{(n_l)}(\mathbf{x}_p^{(i)})$ 近似等于 $\mathbf{x}_p^{(i)}$. 因此, 如果使用 ℓ_2 范数来最小化重构误差, 目标函数变为:

$$J_{AE} = \frac{1}{2} \sum_{i=1}^{|\Omega|} \sum_{p=1}^l \left\| f^{(n_l)}(\mathbf{x}_p^{(i)}) - \mathbf{x}_p^{(i)} \right\|_2^2. \quad (5)$$

寻求最小化每个网络在第 $\frac{n_l}{2}$ 层嵌入空间中行走的所有顶点之间的成对距离, 其形式描述如下:

$$J_{Clique} = \sum_{i=1}^{|\Omega|} \sum_{1 \leq p, q \leq l} \left\| f^{(\frac{n_l}{2})}(\mathbf{x}_p^{(i)}) - f^{(\frac{n_l}{2})}(\mathbf{x}_q^{(i)}) \right\|_2^2 \quad (6)$$

由于输入和输出向量的稀疏性, 考虑使用稀疏自编码器, 并引入稀疏参数 ρ 进行惩罚, 惩罚项采用 Kullback-Leibler 散度^[37],

$$\begin{aligned} \text{KL}(\rho \parallel \hat{\rho}^{(\ell)}) &= \sum_{j=1}^d \text{KL}(\rho \parallel \hat{\rho}_j^{(\ell)}) \\ &= \sum_{j=1}^d \rho \log \frac{\rho}{\hat{\rho}_j} + (1 - \rho) \log \frac{1 - \rho}{1 - \hat{\rho}_j}. \end{aligned} \quad (7)$$

其中 $\hat{\rho}^{(\ell)} = \frac{1}{|\Omega| \times l} \sum_{i=1}^{|\Omega|} \sum_{p=1}^l f^{(\ell)}(\mathbf{x}_p^{(i)})$ 是隐藏层单元的平均激活值. 这个稀疏性约束惩罚了 $\hat{\rho}_j^{(\ell)}$ 与 ρ 的大幅偏离. 给定一个网络游走的训练集 Ω , 则定义整体成本函数为:

$$\begin{aligned} J(\mathbf{W}, \mathbf{b}) &= \underbrace{\sum_{i=1}^{|\Omega|} \sum_{1 \leq p, q \leq l} \left\| f^{(\frac{n_l}{2})}(\mathbf{x}_p^{(i)}) - f^{(\frac{n_l}{2})}(\mathbf{x}_q^{(i)}) \right\|_2^2}_{\text{Clique Embedding Loss}} + \\ &\quad \underbrace{\frac{\gamma}{2} \sum_{i=1}^{|\Omega|} \sum_{p=1}^l \left\| f^{(n_l)}(\mathbf{x}_p^{(i)}) - \mathbf{x}_p^{(i)} \right\|_2^2}_{\text{Reconstruction Error}} + \\ &\quad \underbrace{\beta \sum_{\ell=1}^{n_l-1} \sum_j \text{KL}(\rho \parallel \hat{\rho}_j^{(\ell)})}_{\text{Sparsity Constraint}} + \\ &\quad \underbrace{\frac{\lambda}{2} \sum_{\ell=1}^{n_l} \left\| \mathbf{W}^{(\ell)} \right\|_F^2}_{\text{Weight Decay}}. \end{aligned} \quad (8)$$

其中 $|\Omega|$ 是网络游走的数量, l 是游走长度. 权重衰减项减少了权重的幅度, 并有助于防止过拟合. γ 、 β 和 λ 控制相应惩罚项的权重. 损失函数 $J(\mathbf{W}, \mathbf{b})$ 也可以写成矩阵形式,

$$\begin{aligned} J(\mathbf{W}, \mathbf{b}) &= \sum_{i=1}^{|\Omega|} \text{Tr}(f^{(i)\top} \mathbf{L} f^{(i)}) + \\ &\quad \frac{\gamma}{2} \left\| \mathcal{H}^{(n_l)}(X) - X \right\|_F^2 + \\ &\quad \beta \sum_{\ell=1}^{n_l-1} \text{KL}(\rho \parallel \hat{\rho}^{(\ell)}) + \\ &\quad \frac{\lambda}{2} \left\| W^{(1)} \right\|_F^2 + \frac{\lambda}{2} \sum_{\ell=1}^{n_l-1} \left\| W^{(\ell)} \right\|_F^2. \end{aligned} \quad (9)$$

$$\mathcal{F}^{(i)} = [f_1^{(i)}, f_2^{(i)}, \dots, f_l^{(i)}], f_l^{(i)} = f^{(\frac{n_l}{2})}(\mathbf{x}_l^{(i)}); \mathbf{L}$$

是具有 l 个顶点的团的拉普拉斯矩阵, 因此我们有 $\mathbf{L} = \mathbf{I}_l \times (l - 1) - \Phi$, 且 $\Phi_{i,j} = 1, \forall i \neq j$. $X = [x^{(1)}, x^{(2)}, \dots, x^{(|\Omega|)}]$, $x^{(i)} = [x_1^{(i)}, x_2^{(i)}, \dots, x_l^{(i)}]$; $\mathcal{H}^{(n_l)}(X) = [g^{(1)}, g^{(2)}, \dots, g^{(|\Omega|)}]$, $g^{(i)} = [f^{(n_l)}(x_1^{(i)}), f^{(n_l)}(x_2^{(i)}), \dots, f^{(n_l)}(x_l^{(i)})]$.

我们的目标是 minimized 损失函数 $J(\mathbf{W}, \mathbf{b})$ 关于 $\mathbf{W}$ 和 $\mathbf{b}$ 的函数. 关键步骤是计算目标函数公式(7)关于 $\mathbf{W}$ 和 $\mathbf{b}$ 的偏导数以推导更新. 受反向传播算法^[38]的启发, 我们为隐藏层和输出层分别引入“误差项” $\delta^{(\ell)}$ 和 $\delta^{(n_l)}$. 这些“误差项”可以按以下方式计算:

$$\begin{aligned} \delta^{(n_l)} &= -\gamma \nabla_{f^{(n_l)}(\mathbf{X})} J_{AE} \circ \sigma' \left(h^{(n_l)}(\mathbf{X}) \right) \\ &= -\gamma \left(\mathcal{H}^{(n_l)}(\mathbf{X}) - \mathbf{X} \right) \circ f^{(n_l)}(\mathbf{X}) \circ \left(1 - f^{(n_l)}(\mathbf{X}) \right), \\ \delta^{(\ell)} &= \left(\mathbf{W}^{(\ell)\top} \delta^{(\ell+1)} + \beta \frac{\hat{\rho}^{(\ell)} - \rho_0}{\hat{\rho}^{(\ell)}(1 - \rho_0)} \right) \circ \sigma' \left(h^{(\ell)}(\mathbf{X}) \right) \\ &= \left(\mathbf{W}^{(\ell)\top} \delta^{(\ell+1)} + \beta \frac{\hat{\rho}^{(\ell)} - \rho_0}{\hat{\rho}^{(\ell)}(1 - \rho_0)} \right) \circ f^{(\ell)}(\mathbf{X}) \circ \left(1 - f^{(\ell)}(\mathbf{X}) \right). \end{aligned} \quad (10)$$

其中 ρ_0 是一个所有元素均为 ρ 的向量; “ $\circ$ ” 表示逐元素乘积.

由于群体嵌入损失仅依赖于 $\{\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}\}_{\ell=1}^{\frac{n_l}{2}}$, 那么对于 $\ell > \frac{n_l}{2}$ 的导数是:

$$\nabla_{\mathbf{W}^{(\ell)}} J(\mathbf{W}, \mathbf{b}) = \delta^{(\ell)} \left(f^{(\ell-1)}(\mathbf{X}) \right)^\top + \lambda \mathbf{W}^{(\ell)}, \quad (12)$$

$$\nabla_{\mathbf{b}^{(\ell)}} J(\mathbf{W}, \mathbf{b}) = \sum_{i=1}^{|\Omega|} \delta_i^{(\ell)}. \quad (13)$$

在计算 $\{\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}\}_{\ell=1}^{\frac{n_l}{2}}$ 的导数时, 需要考虑群体嵌入损失.

$$\begin{aligned} \nabla_{\mathbf{W}^{(\ell)}} J(\mathbf{W}, \mathbf{b}) &= \sum_{i=1}^{|\Omega|} \mathcal{F}^{(i)} (\mathbf{L} + \mathbf{L}^\top) \circ \mathcal{F}^{(i)} \circ \\ &\quad (1 - \mathcal{F}^{(i)}) \left(f^{(\ell-1)}(\mathbf{X}) \right)^\top + \\ &\quad \delta^{(\ell)} \left(f^{(\ell-1)}(\mathbf{X}) \right)^\top + \\ &\quad \lambda \mathbf{W}^{(\ell)}, \end{aligned} \quad (14)$$

$$\begin{aligned} \nabla_{\mathbf{b}^{(\ell)}} J(\mathbf{W}, \mathbf{b}) &= \sum_{i=1}^{|\Omega|} \mathcal{F}^{(i)} (\mathbf{L} + \mathbf{L}^\top) \circ \\ &\quad \mathcal{F}^{(i)} \circ (1 - \mathcal{F}^{(i)}) + \delta_i^{(\ell)}. \end{aligned} \quad (15)$$

从每个顶点 $v \in \mathcal{V}$ 开始, 通过随机游走生成所有网络游走. 然后通过优化上述损失函数 $J(\mathbf{W}, \mathbf{b})$ 学习网络表示. 群体嵌入算法的具体步骤如算法1所示.

算法1 群体嵌入算法

输入: 网络游走集 Ω
 输出: 网络表示 $f^{\frac{n_l}{2}}(\mathbf{x}_p^{(i)})$

- 1 设置潜在维数 d , 稀疏性 ρ , 权重控制参数 γ , β 和 λ
- 2 随机初始化 $\{\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}\}_{\ell=1}^{n_l}$
- 3 构造输入向量 $\mathbf{x}_p^{(i)} \in \mathbb{R}^n$ 用于网络游走 i 中的顶点 p , 其中 $1 \leq p \leq l$, $1 \leq i \leq |\Omega|$
- 4 while 不满足条件 δ
- 5 执行前馈传递以计算 $f^{(l)}(x_p^{(i)})$
- 6 对于输出层 n_l , 使用公式(10)设置 $\delta^{(n_l)}$
- 7 for $\ell = n_l - 1, n_l - 2, \dots, 1$ do
- 8 使用公式(11)计算“误差项” $\delta^{(\ell)}$
- 9 if $\ell > \frac{n_l}{2}$ do
- 10 使用公式(12)-(13)计算 $\nabla_{\mathbf{W}^{(\ell)}} J(\mathbf{W}, \mathbf{b})$ 和 $\nabla_{\mathbf{b}^{(\ell)}} J(\mathbf{W}, \mathbf{b})$
- 11 else
- 12 使用公式(14)-(15)计算 $\nabla_{\mathbf{W}^{(\ell)}} J(\mathbf{W}, \mathbf{b})$ 和 $\nabla_{\mathbf{b}^{(\ell)}} J(\mathbf{W}, \mathbf{b})$
- 12 end if
- 13 通过线性搜索确定步长 ξ
- 14 更新 $\mathbf{W}^{(\ell)} = \mathbf{W}^{(\ell)} - \xi \nabla_{\mathbf{W}^{(\ell)}} J(\mathbf{W}, \mathbf{b})$
- 15 更新 $\mathbf{b}^{(\ell)} = \mathbf{b}^{(\ell)} - \xi \nabla_{\mathbf{b}^{(\ell)}} J(\mathbf{W}, \mathbf{b})$
- 16 end for
- 17 end while
- 18 计算嵌入结果 $f^{\frac{n_l}{2}}(\mathbf{x}_p^{(i)})$

4.2.3 边缘编码

CE-PNN学习到顶点的向量表示, 使我们能够基于自适应最近邻检测顶点异常. 接下来我们探讨在边集 $E^{(t)}$ 发生时的边异常检测. 为了确定传入的边是否为异常, 我们构建了一个查找表, 以实时编码新的边, 基于我们已经学习的网络表示. 对于无向网络, 操作符必须是对称的. 也就是说, 对于任何边 (u, v) 或 (v, u) , 边的表示应该是相同的. CE-PNN方法使用了哈达玛积操作符, 它在边编码中表现出了良好的性能. 假设算法1为顶点 v 学习得到的 d 维表示为 $f(v)$, 那么在哈达玛积操作符下, 每条边 (v, u) 的表示为 $[f(v) \circ f(u)]_i = f_i(v) \times f_i(u)$. 值得一提的是, 编码边的方式非常灵活, 我们可以添加任何额外的边特定特征来增强边向量.

4.2.4 增量式维护网络表示

为了应对动态网络的快速演变特性, 我们倾向于更新网络表示, 而不必明确地维护网络结构的完整细节. 本节描述了CE-PNN学习到的网络表示是如何随着网络的变化而动态更新的. 每个添加/删除的边都会影响许多网络游走, 这些游走将用于更新当前的网络表示. 在我们的模型中, 我们设计了一个基于存储库的算法来维护一个紧凑的记录, 该记录由每个顶点的一组邻居组成, 并根据每个顶点的存储库更新行走.

定义3 顶点库(Vertex Reservoir, VR). 对于每个顶点 $v \in \mathcal{V}$, 对应的顶点库 S_v 是一个包含 ψ 项的顶点集合, 由 v 的邻居 $\text{ne}_v = \{u \mid (u, v) \in \mathcal{E}, u \neq v\}$ 替换采样.

给定一个顶点流, CE-PNN为每个顶点 v 维护一个储存库, 这样储存库中的每个项目都是从 v 的邻居中随机选择的. 因此, 当新的边缘到达时, 需要更新储存库. 每增加一条边 (u, v) , 更新规则如下:

- 1) 更新顶点 u 和 v 的度数: $D_{u,u} = D_{u,u} + 1$, $D_{v,v} = D_{v,v} + 1$;
- 2) 对于顶点库 S_v 中的每一项, 以 $\frac{1}{D_{u,u}}$ 的概率将旧项替换为新项; 保留旧项的概率为 $1 - \frac{1}{D_{u,u}}$;
- 3) 对于顶点库 S_u 中的每一项, 以 $\frac{1}{D_{v,v}}$ 的概率将旧项替换为新项; 保留旧项的概率为 $1 - \frac{1}{D_{v,v}}$.

定理1 对于每个 i , 选择顶点 v 的第 i 个邻居以 $\frac{\psi}{D_{v,v}}$ 的概率包含在存储层 S_v 中.

此定理的证明可以通过以下步骤形成:

步骤1 当 $i = 1$, 即 v 的第一个邻居加入时, 存储库 S_v 为空. 此时顶点 v 只有一个邻居, 存储库 S_v 中的所有 ψ 个条目都必须是新邻居 u . 因此, 邻居 u 存在于储库中的概率为1. 此时, $\frac{\psi}{D_{v,v}^{(1)}} = \frac{\psi}{1} = \psi$. 定理成立.

步骤2 假设在处理完第 $(i-1)$ 个邻居后, 对于度数为 $D_{v,v}^{(i-1)}$ 的顶点 v , 其每个邻居在储库 S_v 中存在的概率为 $\frac{\psi}{D_{v,v}^{(i-1)}}$. 当第 i 个邻居加入时, 依据规则更新度 $D_{v,v}^{(i)} = D_{v,v}^{(i-1)} + 1$; 以概率 $\frac{1}{D_{v,v}^{(i)}}$ 用新邻居替换存储库中的某个旧邻居; 以概率 $1 - \frac{1}{D_{v,v}^{(i)}}$ 保留存储库中的旧邻居.

步骤3 如果旧邻居保留在存储库中, 那么旧邻居 $j (j \leq i-1)$ 在第 i 轮仍在存储库中的概率为 $\frac{\psi}{D_{v,v}^{(i-1)}} \times \left(1 - \frac{1}{D_{v,v}^{(i)}}\right)$. 将 $D_{v,v}^{(i)} = D_{v,v}^{(i-1)} + 1$ 代入, $\frac{\psi}{D_{v,v}^{(i-1)}} \times \left(1 - \frac{1}{D_{v,v}^{(i-1)} + 1}\right) = \frac{\psi}{D_{v,v}^{(i-1)}} \times \frac{D_{v,v}^{(i-1)}}{D_{v,v}^{(i-1)} + 1} =$

$\frac{\psi}{D_{v,v}^{(i)}}$, 定理成立. 如果新邻居加入存储库, 因其需被选中且替换某个位置, 替换概率为 $\frac{1}{D_{v,v}^{(i)}}$, 且存储库有 ψ 个可替换位置, 因此新邻居被选入的概率为 $\frac{\psi}{D_{v,v}^{(i)}}$, 定理成立.




图2 存储层更新示意图

Fig. 2 Schematic diagram of storage layer update

在删除边的情况下, 储存库的选择与上述规则类似. 在这种情况下, 需要首先更新度矩阵, 然后用相应顶点的剩余邻居替换被删除的项. 如图3所示, 当在时间戳 t_2 添加 (v_2, v_3) 时, 将分别以 $\frac{1}{3}$ 的概率添加 v_3 和 $\frac{1}{3}$ 的概率添加 v_2 , 从而更新 v_2 和 v_3 对应的储层. 同样, 当 (v_1, v_4) 在时间戳 t_3 被删除时, 我们以1的概率(对应顶点 v_4 只剩下一个邻居)将被删除的项 v_1 替换为 v_3 , 并以 $\frac{1}{2}$ 的概率将被删除的项 v_4 替换为 v_3 或 v_6 .

算法2 增量式网络表示维护算法

输入: 网络游走集 Ω , 流边集 $E^{(t)}$; 群体嵌入模型

输出: 更新后的网络游走集 Ω ; 更新后的群体嵌入模型

```

1 // 动态游走生成
2 for 流边集  $E^{(t)}$  中的  $(u, v)$  do
3   更新顶点集  $V$ 
4   更新度矩阵  $D$ 
5   使用4.2.4节中描述的规则更新存储层  $S_u$  和  $S_v$ 
6   为新边生成网络游走集  $\Omega^+$ , 为删除边生成网络游走集  $\Omega^-$ 
7 end for
8 // 模型更新
9 加载保存的嵌入模型
10 if 边添加 do
11   使用动态网络游走集  $\Omega^+$  和  $\Omega$  中基于梯度采样的部分样本游走集训练模型
12 if 边删除 do
13   使用动态网络游走集  $\Omega - \Omega^-$  中基于梯度采样的部分样本游走集训练模型
14 更新网络表示  $f^{(\frac{n_l}{2})}(\mathbf{x}_p^{(i)})$ 
15 保存更新后的群体嵌入模型

```

在边 (u, v) 到达时, 相应更新的网络游走. 对于每条新添加的边 (u, v) , 需要添加的行走定义为: $\Omega^+ = \{(u_1, u_2, \dots, u_i, u, v, v_1, v_2, \dots, v_j) \vee (v_1, v_2, \dots, v_i, v, u, u_1, u_2, \dots, u_j) | i + j = l - 2\}$, 它是包含新边 (u, v) 的长度为 l 的网络游走的集合. 每个连通的顶点对 (u_m, u_n) 的转移概率为 $p(u_m, u_n) = \frac{1}{D_{u_m, u_n}}$. 对于每条需要移除的边 (u', v') , 动态游走定义为: $\Omega^- = \{\omega | \forall \omega \in \Omega \wedge ((u', v') \in \omega \vee (v', u') \in \omega)\}$. 然后我们将继续用更新后的网络游走集以热启动的方式训练模型.

1) 关于增量式在线训练. 当新边到达时, 理想情况下, 我们会在整个更新后的游走集 $\Omega \cup \Omega^+$ 上重新训练嵌入模型. 然而, 对于大型网络来说, 这在计算上是耗时且昂贵的. 为了在保持表示质量的同时实现效率, 在算法2中针对边添加场景时, 我们采用了一种基于梯度的采样策略来选择模型更新步骤中提到的来自 Ω 的一小部分样本游走集. 该策略优先从 Ω 中采样那些相对于当前模型参数表现出高梯度的游走, 因为这些游走可能对模型更新产生更大的影响. 通过将这些信息丰富的样本与新的游走 Ω^+ 一起关注, 我们可以以有限的计算成本有效地更新模型参数. 对于边删除的情况, 我们通常在更新后的游走集 $\Omega - \Omega^-$ 上直接重新训练模型. 此外, 还可以将边的删除部分直接纳入目标函数公式(9)中进行优化.

$$\begin{aligned}
J(W, b) &= \sum_{i=1}^{|\Omega^+|} \sum_{1 \leq p, q \leq l} \|f^{(\frac{n_l}{2})}(x_p^{(i)}) - f^{(\frac{n_l}{2})}(x_q^{(i)})\|_2^2 + \\
&\sum_{i=1}^{|\Omega^-|} \sum_{1 \leq p, q \leq l} \max(0, \alpha - \|f^{(\frac{n_l}{2})}(x_p^{(i)}) - f^{(\frac{n_l}{2})}(x_q^{(i)})\|_2) + \\
&\frac{\gamma}{2} J_{AE} + \beta J_{Sparsity} + \frac{\lambda}{2} J_{Weight-Decay}.
\end{aligned} \tag{16}$$

2) 在加权网络上. 该算法只需要对现有算法进行少量修改, 即可适应加权网络异常检测. 首先, 由于游走生成步骤采用随机游走器技术, 因此很容易将边的权重考虑到转移概率中. 因此, 在公式(6)中, 需要对两个顶点的成对损失增加权重.

在网络游走生成部分, 在 n 个顶点的网络中生成长度为 l 的 $|\Omega|$ 游走的时间复杂度为 $O(nl|\Omega|)$. 边编码

步骤需要 $O(md)$ 时间来编码顶点维数为 d 的 m 条边. 对于每个新添加的边, 需要 $O(\psi)$ 时间来更新相应的存储库, 并且需要 $O(\psi l)$ 时间来生成需要重新训练的游走.

4.3 自适应最近邻方法

4.3.1 随机森林与自适应最近邻之间的关系

本节分析随机森林和自适应最近邻之间的关系. 首先引入单调距离测度的概念. 在 d 维空间中, 给定两个点 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^d$, 这两个端点在高维空间中处于相对位置, 定义由它们生成的超矩形区域: $\mathcal{R}^d[\mathbf{a}, \mathbf{b}] = \{\mathbf{x} \in \mathbb{R}^d \mid \forall j \in \{1, \dots, d\}, x^j \in [\min(a^j, b^j), \max(a^j, b^j)]\}$, 直观上, 这个超矩形是所有坐标分量均位于 $\mathbf{a}$ 和 $\mathbf{b}$ 之间的点的集合, 如图4(a)所示. 在欧几里得空间中, 任何距离度量都应满足正性条件和三角形不等式. 进一步, 一个合理的距离测度应当满足以下单调性条件: 对于一个距离度量 L , 如果对于超矩形 $\mathcal{R}^d[\mathbf{a}, \mathbf{b}]$ 中的任意点 $\mathbf{c} = (c^1, c^2, \dots, c^d)$, 满足 $L(\mathbf{c}, \mathbf{b}) \leq L(\mathbf{a}, \mathbf{b})$, 即对于由 $\mathbf{a}$ 和 $\mathbf{b}$ 定义的超矩形中的任意两点 $\mathbf{a}$ 和 $\mathbf{b}$ 以及任意点 $\mathbf{c}$, $\mathbf{c}$ 到 $\mathbf{b}$ 的距离小于或等于 $\mathbf{a}$ 到 $\mathbf{b}$ 的距离. 我们将满足这种单调性条件的距离度量称为单调距离测度.

定义4 k 潜在近邻(k -Potential Nearest Neighbors, k -PNN). 当且仅当存在一个单调距离测度 L , 使得 x_k 位于所有样本中与 x_t 最近的 k 个邻居中, 即满足 $L(x_t, x_k) \leq L(x_t, x_i)$, 则称样本 x_k 为目标样本 x_t 的 k -PNN.

自然地, 当且仅当超矩形 $\mathcal{R}_{j=1}^d[x_k^j, x_t^j]$ 中除 x_k 之外的样本点少于 k 个时, 样本 x_k 是 x_t 的 k -PNN, 由距离测度 L 下的 x_k 和 x_t 确定. 在图4(a)中, $\mathbf{b}$ 和 $\mathbf{c}$ 是 $\mathbf{a}$ 的2-PNN, $\mathbf{c}$ 是 $\mathbf{a}$ 的1-PNN, 即潜在最近邻, 定义如下:

定义5 潜在最近邻(Potential Nearest Neighbors, PNN), 当且仅当存在一个单调距离测度 L , 使得在该度量下 x_k 是 x_t 的最近邻, 则称样本 x_k 为目标样本 x_t 的1-PNN.

如图4(b)所示, 未经修剪的决策树在二维空间中将两类样本有效区隔. 整个空间被划分成四个矩形区域, 每个区域均对应一个叶节点, 且每个叶节点仅包含单一类别的数据. 当待测样本 Q 被置于该树结构中, 它将被划分到与叶节点相对应的右上方矩形区域, 从而确定样本 Q 属于正常样本. 决策树 T 在每个节点选

择一个特征进行分割, 以使得该节点的基尼系数最小化. 特征空间通过递归方式被划分成多个超矩形区域, 这些区域在单调度量函数 L 下定义了样本 Q 的潜在最近邻. 样本 Q 的类别由其PNN的类别标签确定. 在分类问题中, 与 Q 位于同一叶节点的最近邻居数量是不固定的.




图3 PNN与决策树: (a)超矩形和潜在最近邻; (b)决策树的递归划分

Fig. 3 PNN and decision tree: (a) Hyperrectangle and potential nearest neighbors; (b) Recursive partitioning of decision trees

显然, 决策树 T 所确定的度量函数 L 与常规的欧氏距离存在本质区别. 特别是在二维的欧几里得空间内, 正面样本与负面样本之间的界限无法通过简单的线性方法进行划分. 然而, 度量函数 L 的设计初衷是为了强化同类样本之间的相似性, 并同时降低异类样本之间的相似性, 以此达到区分不同类别的目的. 通过这种方式, 决策树构建了一个自适应的样本相似性度量机制, 使我们能够更精确地评估样本之间的接近程度. 因此, 我们可以得到以下结论:

定理2 若原始训练集 S 的样本数量为 n , 且训练样本 $(X, Y) \in \mathbb{R}^d \times \mathbb{R}$, 则随机森林 $\{T(X, \theta_k), k = 1, 2, \dots\}$ 对应于一组单调度量函数集合 $\{L_1, L_2, \dots\}$.

此定理的证明可以通过以下步骤形成:

步骤1 首先, 在随机森林的构建过程中, 从原始训练集 S 中通过有放回抽样选取 n 个样本, 构成新的训练集 S' , 并基于此训练集训练一个分类树 h .

步骤2 其次, 指定一个正整数 $mtry \ll d$, 在决策树的每个内部节点上, 从全体 d 个特征中随机抽取 $mtry$ 个特征作为候选特征, 从中选取使得该节点的Gini系数最小化的特征进行分裂.

步骤3 最后, 通过上述特征选择和分裂过程, 每个决策树 h 在 $mtry$ 维的特征空间内实现了超矩形的划分, 即决策树将特征空间划分为多个不相交的超

矩形区域, 每个区域对应于树中的一个叶节点. 因此, 每棵决策树 h 对应一个单一的调度量函数 L . 证毕.

若在随机森林中生成 N_{tree} 棵决策树, 则相应的度量函数集合 $\{L_1, L_2, \dots, L_{N_{tree}}\}$ 为测试样本 $\mathbf{x}_t$ 界定了众多 k -PNN. 样本 $\mathbf{x}_t$ 的预测输出实际上是基于这些潜在邻居集合的值来决定的. 与原始的欧几里得空间中的度量不同, 这些度量函数是通过决策树对训练数据的自学习过程抽象而成的, 展现了一种自适应于 k 近邻规则的动态学习机制.

将 PN_i 定义为随机森林中第 i 棵决策树 T_i 针对测试样本 $\mathbf{x}_t$ 所确定的潜在邻居集合. 在回归问题中,

$$T_i(x_t) = \frac{1}{|PN_i|} \sum PN_i. \quad (17)$$

其中, $|PN_i|$ 是集合 PN_i 中元素的数量, $\sum PN_i$ 是集合 PN_i 中元素的总和.

进一步地, 测试样本 $\mathbf{x}_t$ 的预测值由公式(18)表示:

$$\begin{aligned} f(x_t) &= \frac{1}{N_{tree}} \sum_{i=1}^{N_{tree}} T_i(x_t) \\ &= \frac{1}{N_{tree}} \sum_{i=1}^{N_{tree}} \left(\frac{1}{|PN_i|} \sum PN_i \right). \end{aligned} \quad (18)$$

对于分类问题, 决策树 T_i 未经剪枝处理, 每个叶节点均为纯净状态, 即叶节点内所有训练样本具有相同的类别标签. 因此, 测试样本 $\mathbf{x}_t$ 的预测值实质上是该叶节点上训练样本的类别标签. 故 $T_i(\mathbf{x}_t)$ 相当于公式(19):

$$T_i(x_t) = majority \cdot vote(PN_i). \quad (19)$$

此外, 测试样本 $\mathbf{x}_t$ 的预测是通过公式(20)来表示的:

$$f(x_t) = majority \cdot vote(T_i(x_t))_{i=1}^{N_{tree}}. \quad (20)$$

4.3.2 基于潜在最近邻的改进投票机制

随机森林算法通过Bagging算法从原始训练集中有放回地抽取多个训练样本子集, 以此训练构成森林的多棵决策树. 该过程有效地增加了各决策树之间的独立性, 从而提高组合分类器的性能. 此策略通过提升单棵决策树间的独立度, 有效增强了集成模型的综合预测能力. 然而, 从 k -PNN的角度来看, 每棵决策树 T_i 在其投票过程中仅利用了部分训练数据 S_i , 这意味着决策树 T_i 的OOB样本并不涵盖在由 T_i (基于 $\mathbf{x}_t$ 的单调度量 L_i 对测试样本 $\mathbf{x}_t$ 进行的划分)定义的潜在最近邻居集合中. 因此, 在公式(17)、(18)、(19)和(20)中存在一定程度的信息损失. 尽管这部分

信息的损失相对较小, 但它仍然对最终的分类和回归结果产生了一定的影响.

针对上述问题, 本研究提出了一种在预测过程中考虑OOB样本信息的改进方法. 对于回归问题, 保持公式(17)和公式(18)不变, 在这些公式中引入了OOB样本, 以扩充潜在最近邻(PN_i)的集合. 对于分类问题, 我们注意到公式(19)中大多数样本是具有相同标签的纯训练样本, 并且落在同一叶子节点中的样本 PN_i 内. 相比之下, OOB样本的数量通常较少. 若直接采用简单的多数投票法, OOB样本的信息可能会被训练样本的信息所掩盖. 因此, 本研究设计了一种新的投票机制, 该机制能够更合理地反映OOB样本的信息, 具体如公式(21)所示.

$$f(x_t) = vote \left(\underset{x_i \in S}{\operatorname{argmax}} Fr(x_i) \right). \quad (21)$$

其中, $Fr(\mathbf{x}_i) = \sum_{j=1}^{N_{tree}} fr_j(\mathbf{x}_i)$ 表示样本 $\mathbf{x}_i$ 在潜在最近邻居集 $\{PN_1, PN_2, \dots, PN_{N_{tree}}\}$ 中的出现的频率, $fr_j(\mathbf{x}_i)$ 是 $\mathbf{x}_i$ 在 PN_j 中出现的次数. 目标点 $\mathbf{x}_t$ 的投票点属于 $\mathbf{x}_t$ 的 k -PNN集合. 每棵决策树的终端节点定义一个矩形区域, 若采样点 $\mathbf{x}_t$ 不是 $\mathbf{x}_i$ 的 k -PNN, 则在由 $\mathbf{x}_i$ 和 $\mathbf{x}_t$ 确定超矩形 $\otimes_{j=1}^d [x_i^j, x_t^j]$ 中存在超过 k 个采样点(包括 $\mathbf{x}_t$). 因此, 决策过程中仅有目标点的 k -PNN样本点才能成为有效的投票点. 目标点 $\mathbf{x}_t$ 的所有 k -PNN都有位于与目标点 $\mathbf{x}_t$ 同一终端节点的正概率. 具有最高频率的样本 $\mathbf{x}$ 被定义为随机森林中 $\mathbf{x}_t$ 的潜在最近邻居. 最终, 样本的类标签决定了 $\mathbf{x}_t$ 的类别, 该算法被称为基于随机森林的潜在最近邻(Random Forest-based Potential Nearest Neighbor, RF-PNN)算法.

相比于传统随机森林的加权投票机制, 基于潜在近邻的投票在信息完整性上有根本性提升. 传统加权投票机制存在显著的信息损失. 在每棵决策树的构建过程中, Bootstrap抽样导致约37%的OOB样本被排除在该树的训练集外. 这些样本虽可通过其他树参与预测, 但其局部相似性信息在单棵树决策中被完全忽略. 更关键的是, 随机森林将叶节点内多数类样本压缩为单一类别标签, 导致少数类样本的个体贡献被淹没. 相比之下, 基于潜在近邻的投票机制纳入OOB样本, 每棵树的潜在近邻集合包含全部训练样本, 无论是否属于该树的训练子集, 使OOB样本仍能贡献相似性信息. 同时, 保留样本粒度, 决策基于个体样本的跨树相似频次, 而非叶节点的聚合标签, 这种设计显著提升

了信息利用率. RF-PNN的优点可以概括如下:

1) 在决策树 T_i 中, 只有RF中的训练集 S_i 用于预测样本 $\mathbf{x}_t$. 对于基于转导学习的PNN算法, RF-PNN算法考虑了OOB样本集引起的信息损失.

2) 在预测过程中, 所有决策树都用于RF中的投票. 该过程选择部分PNN样本(与训练集 S_i 中的样本 $\mathbf{x}_t$ 在同一叶节点上的样本)进行投票. RF-PNN算法选择在训练集 S_i 中最接近 $\mathbf{x}_t$ 的样本. 在单调距离度量下 $\{L_1, L_2, \dots, L_{N_{\text{tree}}}\}$, 作为 $\mathbf{x}_t$ 的潜在邻居, 样本的出现频率最高. 这种方法更符合最近邻规则.

算法3 CE-PNN算法

输入: 训练集 $S = \{(\mathbf{x}_i, y_i), i = 1, 2, \dots, n\}$,

$(\mathbf{X}, \mathbf{Y}) \in \mathbb{R}^d \times \mathbb{R}$, 测试集 $\mathbf{x}_t \in \mathbb{R}^d$

输出: 树集合 $\{T_i, i = 1, 2, \dots, N_{\text{tree}}\}$, 对于测试样本 $\mathbf{x}_t$, 决策树 T_i 输出 PN_i

回归问题: $f(\mathbf{x}_t) = \frac{1}{N_{\text{tree}}} \sum_{i=1}^{N_{\text{tree}}} \left(\frac{1}{|\text{PN}_i|} \sum_{\mathbf{x} \in \text{PN}_i} \mathbf{x} \right)$

分类问题: $f(\mathbf{x}_t) = \text{vote}(\arg\max_{\mathbf{x}_i \in S} Fr(\mathbf{x}_i))$

```

1 // 生成随机森林模型
2 for  $i = 1$  to  $N_{\text{tree}}$  do
3   从原始训练集 $S$ 中通过Bootstrap抽样生成训练集 $S_i$ 
4   使用算法1对 $S_i$ 进行网络嵌入, 生成顶点向量表示
5   从 $S_i$ 生成一棵未经修剪的决策树 $T_i$ :
6     随机选择 $m_{\text{try}}$ 个特征, 包括顶点的嵌入向量
7     根据每个节点 $m_{\text{try}}$ 个特征的基尼指数选择最佳特征进行分割
8     进行分割直到树生长到最大深度
9   end for
10 // 寻找自适应最近邻
11 同时将整个训练集 $S$ 和测试样本 $\mathbf{x}_t$ 导入随机森林
12 for  $i = 1$  to  $N_{\text{tree}}$  do
13   搜索具有与决策树 $T_i$ 中的 $\mathbf{x}_t$ 相同的叶子节点的样本集 $\text{PN}_i$ , 即 $\mathbf{x}_t$ 的潜在最近邻
14   if 网络结构有变化 do
15     使用算法2 更新网络表示
16   for  $\text{PN}_i$ 中的每一个样本 do
17     计算 $\mathbf{x}_t$ 与该样本的嵌入向量之间的距离
18   end for
19 end for

```

5 实验

5.1 数据集

为了对本研究所提出方法的有效性进行实证检验, 使用由MLG-ULB提供的Credit Card数据集进行

欺诈检测实验. 原始数据集包含284807笔信用卡交易记录, 其中正常交易284315笔, 欺诈交易492笔, 欺诈交易占比仅为0.172%. 数据集的每个样本都有31个特征, 包括时间戳、交易金额以及通过CAE变换得到的29个合成特征(V1-V28). 由于数据集中欺诈案例的比例极低(约0.17%), 这种极端不平衡可能导致模型训练时产生偏差. 因此, 我们使用W-RUS采样技术, 使正常交易与欺诈交易的比例达到3:1.

其次, 引入IEEE-CIS数据集. IEEE-CIS数据集包含2017年9月至12月的真实交易记录, 共590540条样本. 数据集呈现显著的类别不平衡特性, 欺诈交易占比不足1%. 每条记录包含433维特征, 涵盖交易金额、时间戳、用户行为、设备指纹等多维度信息. 为缓解类别不平衡问题, 本研究采用3:1的W-RUS采样技术平衡正常与欺诈交易样本. 原始数据经过脱敏处理以保护用户隐私, 敏感字段被匿名化.

5.2 实验环境和实验设置

为确保实验结果的公平性与可复现性, 本研究所有实验均在同一高性能计算平台上完成, 以消除环境差异对性能指标的潜在影响. 该平台的标准软件环境为Ubuntu 20.04 LTS, 硬件配置包括Intel Xeon Platinum 8360Y CPU与NVIDIA A100-PCIE-80GB GPU. 为充分发挥硬件性能, 所有模型的训练与评估过程均启用了GPU加速. 软件栈方面, 我们严格遵循各基线模型官方实现的依赖要求, 使用PyTorch 1.13.1(CUDA 11.7)框架, 从而在统一的硬件基础上为每个模型提供其原生的、最优的运行环境. 各基线模型的超参数搜索空间和优化值见表2.

5.3 评价指标和超参数设置

本文使用的实验指标包括分类准确率(Accuracy)、 F_1 分数($F_1 - \text{score}$)和ROC曲线下面积(Area Under ROC Curve, AUC), 这些指标在金融欺诈检测中广泛应用. 同时, 我们用TP(True Positive)表示正确预测的正例, 即实际为欺诈且被模型正确识别为欺诈; FN(False Negative)表示假阴性, 即实际为欺诈但被模型错误判为正常; FP(False Positive)表示假阳性, 即实际为正常但被模型错误判为欺诈; TN(True Negative)表示正确预测的负例, 即实际为正常且被模型正确识别为正常. 各指标的详细定义如下:

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad (22)$$

$$F_1 - score = \frac{2 * precision * recall}{precision + recall}. \quad (23)$$

在金融欺诈检测领域, AUC作为核心性能度量指标, 因其对类别分布不均衡数据的鲁棒性而备受青睐. 该指标通过综合评估模型在不同决策阈值下的真阳性率(TPR)和假阳性率(FPR)之间的曲线下面积, 综合反映模型对正负样本的区分能力. 该指标的取值范围为[0,1], 其值越趋近于1, 则表明模型对正负样本的区分能力越强, 对应的分类器效果越优. TPR和FPR的定义如下:

$$TPR = \frac{TP}{TP + FN}, \quad (24)$$

$$FPR = \frac{FP}{FP + TN}. \quad (25)$$

本研究采用了一种名为树结构帕森估计器(Tree-structured Parzen Estimator, TPE)的贝叶斯优化变体来微调模型超参数. TPE的核心优势在于其评估效率显著高于传统优化的网格搜索或随机搜索技

术——通过基于先前迭代中适应度分数的概率分布引导选择最优超参数组合. 表2列出的十二个超参数通过TPE结合期望改进(Expected Improvement, EI)策略进行了优化, 优化后的超参数值也记录于表中.

5.4 与现有方法的性能比较

5.4.1 欺诈检测性能对比

为了验证CE-PNN方法的有效性, 本文比较了6个最新的金融欺诈检测模型及其改进方法, 分别为Deep SVDD-VAE^[41]、NFA^[42]、HESM^[43]、ScoreGAN^[44]、STAGN^[45]、DDNN^[46]. 同时, 在初始网络的基础上, 通过5倍交叉验证来调整CE-PNN的参数. 此处设置自动编码器网络的层数 n_l 为6. 对于每个编码层, 顶点表示的潜在维数设置为200, 200, 20. 游走长度 l 设为3. 每个顶点的样本数是 $\psi = 20$. 其他参数选择如下: 重构约束权 $\gamma = 5$, 稀疏度比 $\rho = 0.1$, 稀疏度权 $\beta = 0.2$, 权衰减项 $\lambda = 5e - 4$, 簇数 $k = 10$. CE-PNN的最大迭代设置为500. 实验结果如图4所示.

表 2 基线模型的超参数搜索空间和优化值

Table 2 Search Space and Optimal Values of Hyperparameters for Baseline Model

模型	超参数	搜索空间	优化值
Deep SVDD-VAE ^[41]	潜在空间维度	8, 16, 32, 64	32
	编码器/解码器维度	[64, 32], [128, 64], [256, 128]	[128, 64]
	权重损失	0, 0.5, 1.0, 2.0	1.0
	重构损失权重	0, 0.5, 1.0, 2.0	1.0
	学习率	[1e-5, 1e-3], 步长为5e-5	5e-4
NFA ^[42]	嵌入维度	16, 32, 64	32
	RNN 隐层单元数	64, 128, 256	128
	注意力维度	32, 64, 128	64
	丢弃率	0.1, 0.2, 0.5	0.2
STAGN ^[43]	注意力头数	2, 4, 8	4
	图隐层维度	32, 64, 128	64
	时间窗口	5, 10, 15	10
	LeakyReLU参数	0.1, 0.2, 0.3	0.2
HESM ^[44]	RNN隐层单元数	64, 128, 256	128
	霍克斯衰减稀疏	0.1, 0.5, 1.0	0.5
	混合权重	[0.3, 0.7], [0.5, 0.5], [0.7, 0.3]	[0.5, 0.5]
DDNN ^[45]	隐层维度	[64, 32], [128, 64], [256, 128]	[128, 64]
	工作节点数	2, 4, 8	4
	同步步数	5, 10, 20	10
ScoreGAN ^[46]	噪声维度	8, 16, 32, 64	32
	梯度惩罚权重	1.0, 10.0, 100.0	10
	判别器更新次数	1, 5, 10	5
	学习率	[1e-5, 1e-3], 步长为5e-5	5e-4

表3 CE-PNN的超参数搜索空间和优化值

Table 3 Hyperparameters searching space and optimized values of CE-PNN

超参数	搜索空间	优化值
α	0.5, 0.8, 1, 2, 4	0.8
游走长度	[3, 6], 步长为1	4
模型层数	[1, 6], 步长为1	6
γ	[1, 10], 步长为1	5
β	[0.1, 1.0], 步长为0.1	2
λ	[1e-5, 1e-3], 步长为5e-5	5e-4
决策树的数量	[10, 100], 步长为1	15
每棵树的最大深度	[5, 50], 步长为1	38
最佳分割的最大特征数	[1, 13], 步长为1	11
分割内部节点所需的最小样本数	[2, 11], 步长为1	9
在叶节点上所需的最小样本数	[1, 11], 步长为1	1
分裂准则	基尼指数(Gini)或信息增益(Entropy)	Gini

图4、图5给出了本研究提出的CE-PNN与所有对比方法的检测性能,从中可以看出CE-PNN的性能优于所有对比方法,证明了其有效性.其中,横轴表示时间快照,每个快照包含1000条交易数据.此外,通过实验我们得出以下结论:

1) 相比于Deep SVDD-VAE和NFA等已有基于AE的算法模型,CE-PNN有着明显的提升,主要原因是这些模型没有考虑到实际当中欺诈行为的复杂性和动态性.其中,Deep SVDD-VAE通过联合优化VAE与Deep SVDD实现特征学习与边界构建,但其静态图嵌入机制难以适应金融交易网络的动态演化特性.实验数据显示,在CreditCard数据集上,Deep SVDD-VAE的AUC值较CE-PNN低16.72%,主要受限于超球体边界对高维稀疏数据的适应性较差,欺诈样本易被正常行为分布淹没. NFA作为神经分解自编码器,虽能捕获网络电话诈骗的时序模式,但其分解机制在处理多关系金融交易网络时存在缺陷. NFA通过固定阈值过滤可疑节点,但欺诈行为的噪声模式复杂多变,如突发性攻击、伪装正常行为等,固定阈值易导致漏检或误判.本研究通过动态网络流编码和群体

嵌入算法实时更新节点表示,在IEEE-CIS数据集上 $F_1 - score$ 提升13.24%,验证了其对于复杂关系网络的表征优势.

2) 对于HESM和DDNN等捕捉数据中长期和短期时间关系的检测模型,其性能虽较SVM、LSTM、CNN等经典方法略有升高,但仍弱于CE-PNN方法.其中,HESM通过Hawkes过程建模用户行为序列,但其泊松分布假设导致对周期性攻击、突发性欺诈的识别能力不足; DDNN考虑到欺诈数据当中存在的类不平衡情况而对节点进行基于分布式结构的采样,但横向参数聚合引入特征对齐噪声.本文方法在以上方法的基础上引入自适应最近邻机制,从社区演进视角出发对节点的特征进行挖掘,进一步提升聚合后特征的信息价值,进而提升模型性能.实验结果表明,在AUC指标上,CE-PNN比HESM和DDNN分别提升4.49%和6.72%,反映其对时序特征的全局聚合能力




图4 CE-PNN与现有6个欺诈检测模型的AUC比较

Fig. 4 Comparison of AUC between the CE-PNN method and six existing fraud detection models

3) ScoreGAN引入对抗生成框架与评分驱动的约束机制, STAGN利用图神经网络学习交易图的节点与全局表示以捕捉时空模式, 再通过时空注意力机制动态加权关键时序片段和空间热点, 提取多维时空交互特征. 这两种方法在性能上较之前的方法都有所提升, 但弱于本文方法. 本文提出的CE-PNN方法能够通过合适的随机游走算法对特定欺诈场景下的节点特征进行深度挖掘, 提升模型整体性能. 且考虑OOB样本信息, 通过潜在最近邻挖掘多关系图特征集成层间的紧密关系, 能够在一定程度上规避伪装与噪声带来的负面影响, 从而进一步升模型在欺诈检测当中的精




图 5 CE-PNN与现有6个欺诈检测模型的 F_1 - score比较

Fig. 5 Comparison of F_1 - score between the CE-PNN method and six existing fraud detection models

5.4.2 实时金融欺诈检测延迟对比

本实验通过模拟流式处理环境, 以每批次1000条交易数据的增量处理方式, 对CE-PNN方法与其他6种主流欺诈检测模型在实时金融欺诈检测场景下的延迟性能进行了对比分析. 核心目标验证各模型在实时场景下的延迟性能, 以验证各模型是否满足毫秒级延迟要求. 实验从数据采样、特征嵌入到分类推理的全流程耗时进行量化测量, 实验结果如表4所示.

表 4 CE-PNN与现有6个欺诈检测模型的延迟对比

Table 4 Latency comparison between CE-PNN and six fraud detection models

方法	数据 采样 耗 时(ms)	特征 嵌入 耗 时(ms)	分类 推理 耗 时(ms)	总耗 时(ms)	是否 满 足<100ms
Deep SVDD-VAE	12.5	102.7	7.3	122.5	否
NFA	10.1	88.9	6.5	105.5	否
STAGN	11.3	95.4	8.2	114.9	否
HESM	9.8	78.2	6.9	94.8	是
DDNN	13.6	108.3	7.8	129.7	否
ScoreGAN	14.2	115.1	8.5	137.8	否
CE-PNN	8.2	15.3	5.1	28.6	是

从总耗时来看, CE-PNN以28.6ms的总耗时位列第一, 且唯一满足<100ms的严格实时性要求. 相较之下, 现有模型中仅有HESM的总耗时接近临界值, 其余模型的总耗时均超过阈值, 未能达到金融场景对实时性的严苛要求. 这一结果表明, CE-PNN在全流程优化方面具有突出效能, 尤其适用于对响应速度敏感的实时欺诈检测任务.

分阶段耗时分析进一步揭示了CE-PNN的性能优势来源. 在数据采样环节, CE-PNN以8.2ms的耗时领先于其他模型, 较第二低的HESM的9.8ms降低16.3%, 体现出其在动态数据筛选机制上的高效性. 特征嵌入阶段, CE-PNN的耗时仅为15.3ms, 显著低于表现次优的HESM(78.2ms)和NFA(88.9ms), 降幅分别达80.4%和82.8%, 这可能得益于其特征提取算法的结构优化或并行计算设计. 分类推理环节, CE-PNN以5.1ms的耗时成为所有模型中最快的推理引擎, 较传统深度神经网络模型DDNN和生成对抗网络模型ScoreGAN分别提升34.6%和40.0%, 显示出其在模型轻量化与推理加速方面的技术突破.

综上, 实验结果表明, CE-PNN方法通过端到端的流程优化, 在数据采样、特征嵌入和分类推理各环节均实现了显著的性能提升, 其端到端总耗时远低于现有模型, 满足金融场景毫秒级延迟要求. 这一结果不仅验证了CE-PNN在实时欺诈检测任务中的技术可行性, 也为后续面向低延迟需求的智能模型设计提供了重要的参考范式, 尤其在需要平衡模型精度与推理效率的金融应用场景中具有较高的应用价值.

5.5 消融实验

本节通过设计消融实验来验证CE-PNN方法三个关键模块的有效性, 构造3个变体方法如下:

- 1) CE-PNN/r: 在完整方法CE-PNN中, 只使用集成学习组件和特征增强组件, 而不使用标签平衡采样组件;
- 2) CE-PNN/c: 在完整方法CE-PNN中, 只使用标签平衡采样组件和特征增强组件, 而不使用集成学习组件;
- 3) CE-PNN/f: 在完整方法CE-PNN中, 只使用标签平衡采样组件和集成学习组件, 而不使用特征增强组件.

表 5 CE-PNN 方法及其3个变体方法的检测性能

Table 5 Detection performance of CE-PNN method and its 3 variant methods

方法	CreditCard		IEEE-CIS	
	F_1 -score	AUC	F_1 -score	AUC
CE-PNN/r	0.7265	0.8832	0.7295	0.9124
CE-PNN/c	0.7639	0.8992	0.7425	0.9366
CE-PNN/f	0.7457	0.8975	0.7338	0.9275
CE-PNN	0.7726	0.9236	0.7595	0.9493

实验结果如表5所示. 首先, 从表5中可以看出, CE-PNN/r在CreditCard数据集上的 F_1 -score和AUC显著低于完整模型, 表明标签平衡采样模块在欺诈检测任务中具有必要性. CE-PNN/r模型因缺失该模块, 仅依赖集成学习与特征增强组件, 导致训练阶段欺诈样本与正常样本的比例失衡, 进而使模型对少数类特征的捕捉能力受限. 这说明增强少数类特征能够有效的提高检测性能.

其次, 实验结果表明, 与完整方法CE-PNN相比, CE-PNN/c方法在CreditCard和IEEE-CIS数据集上的三个性能评估指标均降低. 主要原因是单个分类器通常由于其固定的假设而受到限制, 难以多样复杂的金融欺诈行为, 说明利用随机森林的自适应分裂准则, 集成后的欺诈检测机制能提升欺诈检测率.

从实验结果中还可以发现, CE-PNN/f方法仅采用标签平衡采样组件和集成学习组件, 未引入特征增强组件, 导致最终学习到的欺诈类和良性类样本的特征区分度不够明显. 这一结果说明, 缺乏基于编码网络流的特征提取组件的处理, 使得数据集的原始节点特征无法有效地反映节点的实际信息. 相比之下, 通过

随机网络游走对节点嵌入表示进行拓展, 能够更精确地捕捉节点的复杂特性, 从而有效地提升模型的检测性能.

5.6 动态网络中的维护性能

为了评估CE-PNN算法在动态网络中的维护性能, 特别是在流式网络环境中如何有效地更新网络表示. 本节在UCI Messages数据集上对比了DeepWalk、node2vec、CE-PNN^S和CE-PNN四种网络嵌入方法, 在多个时间快照上的游走生成时间(以秒计)和异常检测的AUC分数.

值得注意的是, CE-PNN利用储层采样技术来增量地维护网络表示. 具体来说, CE-PNN为每个包含其邻居的顶点创建一个储存库, 并且基于这些储存库生成新的网络游走, 而不会将整个网络存储在内存中. 而CE-PNN^S需要将网络保存在内存中, 并根据UCI消息的当前时间戳生成基于整个网络的游走, 异常率为5%.




图 6 动态维护性能评价

Fig. 6 Dynamic maintenance performance evaluation

由图6可知, CE-PNN的平均AUC分数为0.7329, 高于CE-PNN^S的0.7307. 然而, CE-PNN^S的游走生成时间比CE-PNN长5.0到10.2倍. 与CE-PNN^S类似, DeepWalk和node2vec也需要在内存中保持整个网络以更新游走. 因此, DeepWalk和node2vec生成游走的时间比我们的模型长5倍到11倍. 对于SDNE, 与其他基线相比, 其在网络层面计算一阶邻近度的操作非常耗时.

5.7 参数敏感性分析

本小节探索和分析CE-PNN方法中两个主要参数, mtry和ntree(上文提到的 N_{tree})对检测性能的影响.

响. 由于欺诈检测数据集尚未进行预先的数据划分, 因此选择10折交叉验证方法而非OOB准确率来度量模型的性能.

mtry参数表示每棵树生长过程中每个节点随机选择的候选特征的数量, 一般设为特征总数的平方根. 本实验选取信用卡欺诈检测数据集, 用以评估不同mtry参数对模型性能的影响. ntree参数表示森林中决策树的数量, 其值由具体数据集的特性决定. 当ntree参数较小时, 模型的分类误差相对较大. 由于随机森林算法本身不易发生过拟合, 我们可以通过增加ntree的值来提高集成分类器的多样性. 但值得注意的是, 构建过大ntree值的模型在一定程度上会增加计算时间. 在本项工作中, 我们首先在ntree设定为100的条件下确定mtry参数, 并进一步评估了两种模型的性能表现.




图7 不同mtry参数下两种模型的性能

Fig. 7 Performance of the two models with different mtry parameters

实验结果如图7所示, 图中的纵轴表示不同mtry值下两种模型的分类准确率, 横轴代表mtry参数. 当参数mtry达到3(默认值, 即随机森林中特征总数的平方根)后, 两种模型的性能结果趋于稳定. 这一现象表明, 两种方法对于mtry参数具有较好的鲁棒性. 参数mtry决定了算法的随机化程度. 对于RF模型, 较大的mtry值有助于在降低方差的同时提升性能. 而CE-PNN模型在mtry处于其取值范围的中间值时, 其性能表现较为稳定.

如上所述, $ntree = \{10, 20, \dots, 100, 150, 200, \dots, 500, 1\,000, 2\,000, \dots, 5\,000\}$, mtry参数设置为3.

对每种配置执行了100次10折交叉验证. 图8展示了两种算法在100次10折交叉验证中的准确率对比, 其中纵轴表示平均准确率, 横轴表示决策树的数量.




图8 不同ntree参数下精度比较

Fig. 8 Accuracy comparison with different ntree parameters

设 Acc_1 为随机森林算法的平均准确率, Acc_2 为CE-PNN算法的平均准确率. 图9描绘了在欺诈数据集上, 随着森林规模从10增至5000, 两种模型准确率差异的变化情况, 即 $Acc_2 - Acc_1$, Acc_1 与 Acc_2 的差值.




图9 不同决策树下两种模型的准确率差异

Fig. 9 Accuracy difference of the two models with various decision trees

从以上实验结果可以得出以下结论:

1) 两种模型的性能随森林规模的变动而波动. 在决策树数量较少时, 两种模型的效果尚未达到最佳. 随着森林规模的扩大, 算法性能得到改善并逐渐稳定(当决策树数量接近100时). 即使森林规模扩展至千树级别, 也未发现过拟合现象. 过大的决策树数量并未导致集成分类器性能的降低. 这一特性说明两模型对于模型的ntree参数具有较好的鲁棒性.

2) CE-PNN模型的平均分类性能优于RF. 如图7所示, 从参数mtry对模型分类准确率和方差的影响来看, CE-PNN在稳定性方面超越了RF. 如图8所示, 在不同森林规模下, CE-PNN的平均分类准确率均高于RF. 图9进一步展示了在不同森林规模下CE-PNN相较于RF的性能提升. 结果指出, 所有规模的森林性能均有所增强.

其次, 与RF相比, CE-PNN在OOB样本上对特定数据集的分类效果有所提升. 如果某些节点上OOB样本数量较少甚至缺失, 则CE-PNN的效果与RF相近, 这就是在某些数据集中提升效果不显著的原因. 此外, 当算法已经实现显著的分类效果时, 进一步提升分类器性能将面临挑战. 在图8中, RF的准确率已达90%, 因此CE-PNN的进一步改进空间相对有限.

再次, 从图8的变化趋势可以看出, 两种模型在随机森林规模的波动上呈现出相似性, 这表明CE-PNN的分类性能提升仍然受到RF的影响, 尽管CE-PNN的分类性能优于RF. 该改进是在RF的基础上实现的, 但随着决策树数量的增减, 两种模型的性能也随之变化. 值得注意的是, 即便在森林规模不断扩大且性能趋于稳定的情况下, CE-PNN的性能优势依然明显. 这一现象充分证实了CE-PNN的改进效果是显著的, 且并非由随机因素引起.




图 10 不同超参数值下CE-PNN的ROC曲线

Fig. 10 ROC curves of CE-PNN with different hyperparameter values

综上可知, 需要选择合适的超参数才能够使得CE-PNN方法的检测性能达到最佳, 过大或过小的超参数都会影响模型最终的检测性能.

5.8 采样阈值敏感性分析

为验证加权随机欠采样中频率阈值设定的科学性, 并系统评估不同数据平衡程度对模型性能的影响,

本实验在CreditCard和IEEE-CIS两个真实金融欺诈数据集上, 设计了采样阈值敏感性分析. 实验设置了良性样本与欺诈样本之比从不采样(原始不平衡)、10:1、5:1、3:1、2:1到1:1的共六个梯度, 旨在探究不同阈值对CE-PNN模型在分类性能AUC、 F_1 -score、训练效率及特征嵌入质量上的综合影响. 所有实验均在统一的软硬件环境下, 采用5折交叉验证并重复运行3次, 最终取平均值与标准差, 以确保实验结论的统计显著性与可靠性.

表 6 CreditCard数据集上不同采样比例的性能对比

Table 6 Performance comparison under different sampling ratios on the CreditCard dataset

采样比例	数据集规模	AUC	F_1 -score	采样时间(ms)	训练时间(ms)	分离度
原始	284807	0.8412	0.6014	-	189.5	1.23
10: 1	5412	0.8725	0.6589	6.1	45.2	1.89
5: 1	2953	0.8963	0.7124	5.8	32.7	2.34
3: 1	1968	0.9236	0.7726	5.5	28.6	2.87
2: 1	1476	0.9187	0.7632	5.3	26.1	2.91
1: 1	984	0.9015	0.7448	5.1	24.3	2.95

表 7 IEEE-CIS数据集上不同采样比例的性能对比

Table 7 Performance comparison under different sampling ratios on the IEEE-CIS dataset

采样比例	数据集规模	AUC	F_1 -score	采样时间(ms)	训练时间(ms)	分离度
原始	590540	0.8642	0.5847	-	245.3	1.35
10: 1	64859	0.9016	0.6728	8.7	68.9	2.01
5: 1	35432	0.9285	0.7216	8.2	52.4	2.52
3: 1	23621	0.9493	0.7595	7.9	41.7	2.94
2: 1	17716	0.9438	0.7512	7.6	38.2	3.01
1: 1	11810	0.9315	0.7283	7.3	34.8	3.11

实验结果表明, 3:1的采样比例达到最优性能: 在CreditCard上AUC为0.9236, F_1 -score为0.7726; 在IEEE-CIS上AUC为0.9493, F_1 -score为0.7595. 该比例在缓解类别不平衡与保留拓扑结构信息间达到了最佳平衡, 且使训练效率提升约85%. 对比分析显示, 当比例低于3:1时, 因过度削减多数类样本导致关键结构信息丢失; 高于3:1时, 类别不平衡问题缓解不足. 基于双数据集的一致性结论, 本文推荐3:1作为金融欺诈检测任务的通用采样阈值.

6 总结

目前金融领域的欺诈检测技术面临着诸如类别不平衡、噪声干扰严重以及分类器准确度有限等挑战, 这些问题导致检测效果不尽人意. 针对这些问题, 本文提出了一种CE-PNN方法, 该方法依据欺诈发生的频率对训练数据进行采样, 以实现数据的平衡处理. 然后通过群体嵌入增强节点的特征嵌入, 最后采用 k 个潜在近邻的自适应学习机制和基于潜在最近邻的改进投票机制, 以增强集成分类器的整体分类精度. 本文所提出的框架对于整合多源数据, 提高数据处理效率, 实现金融欺诈检测的多维度分析具有参考价值.

参考文献:

- [1] Hafez I Y, Hafez A Y, Saleh A, et al. A systematic review of AI-enhanced techniques in credit card fraud detection. *Journal of Big Data*, 2025, 12(1): 6.
- [2] Wu Y, Xie Z, Ji S, et al. Fraud-agents detection in online microfinance: A large-scale empirical study. *IEEE Transactions on Dependable and Secure Computing*, 2022, 20(2): 1169-1185.
- [3] Vorobyev I. Fraud risk assessment in car insurance using claims graph features in machine learning. *Expert Systems with Applications*, 2024, 251: 124109.
- [4] Achakzai M A K, Peng J. Detecting financial statement fraud using dynamic ensemble machine learning. *International Review of Financial Analysis*, 2023, 89: 102827.
- [5] Mutemi A, Bacao F. E-commerce fraud detection based on machine learning techniques: Systematic literature review. *Big Data Mining and Analytics*, 2024, 7(2): 419-444.
- [6] Unnithan A B, Laroche M, Kumar A. Masstige marketing in 2023 and beyond: An introduction to the special issue on masstige marketing. *International Journal of Consumer Studies*, 2024, 48(2): e13018.
- [7] Sun J, Jia Y, Wang Y, et al. Ethereum fraud detection via joint transaction language model and graph representation learning. *Information Fusion*, 2025, 120: 103074.
- [8] LIU X, Zhang X, Wu Z, et al. Non-intrusive detection method of F-DI attack in heating network. *Control Theory & Applications*, 2025, 42(07): 1265-1274.
(刘鑫蕊, 张修宇, 吴泽群, 等. 热网FDI攻击的非侵入式检测方法. 控制理论与应用, 2025, 42(07): 1265-1274.)
- [9] Wang C, Wang C J. An Automated Feature Engineering Method for Online Payment Fraud Detection[J]. *Chinese Journal of Computers*, 2020, 43(10): 1983-2001.
(王成, 王昌琪. 一种面向网络支付反欺诈的自动化特征工程方法. 计算机学报, 2020, 43(10): 1983-2001.)
- [10] Van Belle R, Baesens B, De Weerd J. CATCHM: A novel network-based credit card fraud detection method using node representation learning. *Decision Support Systems*, 2023, 164: 113866.
- [11] Luo X, Wang G, Liao W, et al. Semi-supervised medical image segmentation via uncertainty rectified pyramid consistency. *Medical Image Analysis*, 2022, 80: 102517.
- [12] Kouam A J, Viana A C, Tchana A. SIMBox bypass frauds in cellular networks: Strategies, evolution, detection, and future directions. *IEEE Communications Surveys & Tutorials*, 2021, 23(4): 2295-2323.
- [13] Cui J, Kim K, Na S H, et al. Meta-path-based fake news detection leveraging multi-level social context information. *Proceedings of the 31st ACM international conference on information & knowledge management*. 2022: 325-334.
- [14] Liu Z, Dou Y, Yu P S, et al. Alleviating the inconsistency problem of applying graph neural network to fraud detection. *Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval*. 2020: 1569-1572.
- [15] Dou Y, Liu Z, Sun L, et al. Enhancing graph neural network-based fraud detectors against camouflaged fraudsters. *Proceedings of the 29th ACM International Conference on Information & Knowledge Management*, 2020: 315-324.
- [16] Hilal W, Gadsden S A, Yawney J. A review of anomaly detection techniques and applications in financial fraud. *Expert Systems with Applications*, 2021, 116429.
- [17] Zhao S, Zhang B, Yang J, et al. Linear discriminant analysis. *Nature Reviews Methods Primers*, 2024, 4(1): 70.
- [18] Zhu F, Gao J, Yang J, et al. Neighborhood linear discriminant analysis. *Pattern Recognition*, 2022, 123: 108422.
- [19] Xia, Z, Chen Y, Xu C. Multiview PCA: A methodology of feature extraction and dimension reduction for high-order data. *IEEE Transactions on Cybernetics*, 2021, 52(10): 11068-11080.
- [20] Anowar F, Sadaoui S, Selim B. Conceptual and empirical comparison of dimensionality reduction algorithms (pca, kpca, lda, mds, svd, lle, isomap, le, ica, t-sne). *Computer Science Review*, 2021, 40: 100378.
- [21] Xu W, Jiang Q, Shen Y, et al. RUL prediction for rolling bearings based on Convolutional Autoencoder and status degradation model. *Applied Soft Computing*, 2022, 130: 109686.
- [22] Hu H X, Cao C, Hu Q, et al. A real-time bearing fault diagnosis model based on siamese convolutional autoencoder in industrial internet of things. *IEEE Internet of Things Journal*, 2023, 11(3): 3820-3831.
- [23] Li W, Shang Z, Zhang J, et al. A novel unsupervised anomaly detection method for rotating machinery based on memory augmented temporal convolutional autoencoder. *Engineering Applications of Artificial Intelligence*, 2023, 123: 106312.
- [24] Huleihel Y, Permuter H H. Low papr mimo-ofdm design based on convolutional autoencoder. *IEEE Transactions on Communications*, 2024, 72(5): 2779-2792.
- [25] Hilal W, Gadsden S A, Yawney J. Financial fraud: a review of anomaly detection techniques and recent advances. *Expert systems With applications*, 2022, 193: 116429.
- [26] Jiang Y, Liu G, Wu J, et al. Telecom fraud detection via hawkes-enhanced sequence model. *IEEE Transactions on Knowledge and Data Engineering*, 2022, 35(5): 5311-5324.
- [27] Forough J, Momtazi S. Ensemble of deep sequential models for credit card fraud detection. *Applied Soft Computing*, 2021, 99: 106883.
- [28] Li K, Huang Z. Noise Filtering and Feature Enhancement Based Graph Neural Network Method for Fraud Detection. *ACTA ELECTRONICA SINICA*, 2023, 51(11): 3053-3060.
(李康和, 黄震华. 基于噪声过滤与特征增强的图神经网络欺诈检测方法. 电子学报, 2023, 51(11): 3053-3060.)

- [29] Zhao W, Li L, Alam S, et al. An incremental clustering method for anomaly detection in flight data. *Transportation Research Part C: Emerging Technologies*, 2021, 132: 103406.
- [30] Lucas Y, Portier P E, Laporte L, et al. Towards automated feature engineering for credit card fraud detection using multi-perspective HMMs. *Future Generation Computer Systems*, 2020, 102: 393-402.
- [31] Aftabi S Z, Ahmadi A, Farzi S. Fraud detection in financial statements using data mining and GAN models. *Expert Systems with Applications*, 2023, 227: 120144.
- [32] Akinyelu A A, Ezugwu A E, Adewumi A O. Ant colony optimization edge selection for support vector machine speed optimization. *Neural Computing and Applications*, 2020, 32(15): 11385-11417.
- [33] Tang Y, Liang Y. Credit card fraud detection based on federated graph learning. *Expert Systems with Applications*, 2024, 256: 124979.
- [34] Song H, Wang X, Wang Z. Nonlinear multi-model second level generalized predictive control based on switching. *Control Theory & Applications*, 2024, 41(11): 2147-2156.
(宋红超, 王昕, 王振雷. 基于切换的非线性多模型二阶段广义预测控制. 控制理论与应用, 2024, 41(11): 2147-2156.)
- [35] Sisodia D, Sisodia D S. Feature space transformation of user-clicks and deep transfer learning framework for fraudulent publisher detection in online advertising. *Applied Soft Computing*, 2022, 125: 109142.
- [36] Kumari A, Lobiyal D K. Efficient estimation of Hindi WSD with distributed word representation in vector space. *Journal of King Saud University-Computer and Information Sciences*, 2022, 34(8): 6092-6103.
- [37] Mikolov T, Sutskever I, Chen K, et al. Distributed representations of words and phrases and their compositionality. *Advances in neural information processing systems*, 2013, 26.
- [38] Perozzi B, Al-Rfou R, Skiena S. Deepwalk: Online learning of social representations. *Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining*. 2014: 701-710.
- [39] Zhang Y, Pan J, Liu W, et al. Kullback-Leibler divergence-based out-of-distribution detection with flow-based generative models. *IEEE Transactions on Knowledge and Data Engineering*, 2023, 36(4): 1683-1697.
- [40] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors. *nature*, 1986, 323(6088): 533-536.
- [41] Zhou Y, Liang X, Zhang W, et al. VAE-based deep SVDD for anomaly detection. *Neurocomputing*, 2021, 453: 131-140.
- [42] Wahid A, Msahli M, Bifet A, et al. NFA: A neural factorization autoencoder based online telephony fraud detection. *Digital Communications and Networks*, 2024, 10(1): 158-167.
- [43] Cheng D, Wang X, Zhang Y, et al. Graph neural network for fraud detection via spatial-temporal attention. *IEEE Transactions on Knowledge and Data Engineering*, 2020, 34(8): 3800-3813.
- [44] Jiang Y, Liu G, Wu J, et al. Telecom fraud detection via hawkes-enhanced sequence model. *IEEE Transactions on Knowledge and Data Engineering*, 2022, 35(5): 5311-5324.
- [45] Lei Y T, Ma C Q, Ren Y S, et al. A distributed deep neural network model for credit card fraud detection. *Finance Research Letters*, 2023, 58: 104547.
- [46] Shehnepoor S, Togneri R, Liu W, et al. ScoreGAN: A fraud review detector based on regulated GAN with data augmentation. *IEEE Transactions on Information Forensics and Security*, 2021, 17: 280-291.

作者简介:

蒋伟进 教授, 博士, 目前研究方向为联邦学习, 边缘计算, 异常检测, E-mail: jwj3666@163.com;

刘茜 硕士研究生, 目前研究方向为异常检测, 欺诈检测, E-mail: 726956360@qq.com;

聂彩燕 硕士研究生, 目前研究方向为群智感知, 隐私保护, E-mail: 516278890@qq.com;

杨璇 硕士研究生, 目前研究方向为联邦学习, 隐私保护, E-mail: 1064174495@qq.com;

杜熙晨 硕士研究生, 目前研究方向为联邦学习, 群智感知, E-mail: dxcstu@163.com.