

异构环境下基于目标扰动的群智感知隐私保护策略

蒋伟进^{1,3}, 王海娟^{1,2†}, 李一骁^{1,3}, 蒋意蓉⁴

(1. 湖南工商大学, 湖南 长沙 410205; 2. 国防科技大学, 湖南 长沙 410205;

3. 湘江实验室, 湖南 长沙 410205; 4. 湖南信息学院 艺术学院, 湖南 长沙 410151)

摘要: 联邦学习架构下的移动群智感知用户存在隐私泄露风险, 现有基于差分隐私的方案在梯度裁剪过程中会引起本地模型训练精度的缺失, 这种现象在异构环境中表现尤为不佳. 为了解决上述问题, 本文首先采用联邦随机主成分分析法对数据进行降维处理; 随后, 将经过Rényi-差分隐私扰动后的目标函数替代梯度进行更新. 然后, 引入Bregman散度作为正则化项更新损失函数, 约束本地模型与全局模型的偏离. 实验结果表明, 本文所提出的方法与现有几种方法相比具有更高的准确性和收敛精度.

关键词: 移动群智感知; 隐私保护; Rényi-差分隐私; 异构

引用格式: 蒋伟进, 王海娟, 李一骁, 等. 异构环境下基于目标扰动的群智感知隐私保护策略. 控制理论与应用, 2025, 42(11): 2374 – 2385

DOI: 10.7641/CTA.2025.50127

Target perturbation-based privacy protection for crowdsensing under heterogeneous conditions

JIANG Wei-jin^{1,3}, WANG Hai-juan^{1,2†}, LI Yi-xiao^{1,3}, JIANG Yi-rong⁴

(1. Hunan University of Technology and Business, Changsha Hunan 410205, China;

2. National University of Defense Technology, Changsha Hunan 410205, China;

3. Xiangjiang Laboratory, Changsha Hunan 410205, China;

4. College of Art, Hunan University of Information Technology, Changsha Hunan 410151, China)

Abstract: In federated learning architectures for mobile crowdsensing, users face the risk of privacy leakage. Existing differential privacy-based schemes suffer from a loss of local model training accuracy due to gradient clipping, especially in heterogeneous environments. To address these issues, our paper first employs federated stochastic principal component analysis to reduce the dimensionality of the data. Subsequently, the objective function perturbed by rényi-differential privacy is used to replace the gradient for updates. Then, Bregman divergence is introduced as a regularization term to update the loss function, constraining the deviation between the local and global models. Experimental results demonstrate that the proposed method achieves higher accuracy and convergence precision compared to several existing approaches.

Key words: mobile crowdsensing; privacy protection; rényi-differential privacy; heterogeneity

Citation: JIANG Weijin, WANG Haijuan, LI Yixiao, et al. Target perturbation-based privacy protection for crowdsensing under heterogeneous conditions. *Control Theory & Applications*, 2025, 42(11): 2374 – 2385

1 引言

随着第5代移动通信和物联网技术的突破性发展, 移动群智感知 (mobile crowdsensing, MCS) 系统通过海量终端设备协同采集动态环境数据^[1-2], 逐渐成为城市级实时感知的重要范式. 但传统MCS架构依赖于

集中式数据汇聚与处理, 这不仅存在用户隐私泄露的风险, 还可能因大规模数据传输产生高昂的通信成本^[2]. 基于联邦学习 (federated learning, FL) 的MCS框架 (FL-MCS) 使用分布式机制, 参与者仅需上传梯度更新而非敏感原始数据^[3], 有效降低了中心化处理过

收稿日期: 2025-03-29; 录用日期: 2025-09-26.

†通信作者. E-mail: 2502560411@qq.com.

本文责任编辑: 王凌.

国家自然科学基金项目 (61772196, 72088101), 长沙市社科规划项目 (2024CSSKKT31), 湖南省教育厅科学研究重点项目 (24A0446, 24A0753) 资助.

Supported by the National Natural Science Foundation of China (61772196, 72088101), the Changsha Social Science Planning Project (2024C-SSKKT31) and the Key Scientific Research Projects of Hunan Provincial Department of Education (24A0446, 24A0753).

程中的数据隐私泄露风险和大规模数据传输带来的通信开销^[4], 为构建安全、高效的智慧城市等大规模分布式场景提供了新的技术路径, 架构示意图如图1所示。




图 1 FL-MCS架构示意图

Fig. 1 Schematic diagram of the FL-MCS architecture

在FL-MCS部署过程中, 参与者隐私保护的有效性已成为制约其高质量应用的重要挑战^[5]。由于参与者上传的感知数据通常包含时空轨迹、生物特征等敏感信息, 隐私泄露不仅会显著降低用户参与意愿, 还可能引发身份盗用、行为推断等严重安全威胁。针对该问题, 已有相关专家提出相关隐私保护方案^[6-11]。当前, 大多数FL-MCS隐私保护方案采用经典的隐私保护技术如同态加密、秘密共享方法等融入FL中^[11]。但相比于上述传统密码学技术, 差分隐私(differential privacy, DP)^[12]凭借其坚实的数学基础和可控的隐私-效用平衡特性, 在FL中展示出显著优势。相比于同态加密等需要引入额外计算复杂度的方法, DP只需要添加少量噪声, 便可以实现高效的隐私保护。DP的扰动机制可作用于数据生成、梯度更新、目标函数优化及模型输出等多个阶段^[13]。噪声的扰动程度与隐私预算密切相关^[10], 隐私预算越小, 扰动的噪声越大, 隐私保护效果越强, 从而DP可以在FL-MCS中实现高效的隐私保护。

然而, 当前基于加噪的隐私保护机制通常需要兼顾MCS-FL模型准确率与隐私性的平衡。FL中每个客户端需要基于本地数据独立计算梯度。现有基于DP-随机梯度下降算法(stochastic gradient descent, SGD)的方法^[14-15], 在进行梯度裁剪时往往会出现梯度精度丢失的问题导致模型收敛速度和性能降低^[15]。当前绝大多数基于DP的研究^[11-17]采用固定裁剪阈值、敏感度以及噪声尺度的方式, 即每轮全局通信时各个参与方为模型参数(或梯度)注入相同的噪声方差。这些研究虽能为参与方数据提供本地差分隐私(local DP, LDP)保证, 但仍存在模型效用低、隐私-效用权衡不佳等不足。为增强参与方本地数据隐私, 部分前沿研

究采用梯度压缩或稀疏化方法^[18-21], 但这些方法仍面临信息丢失风险如Top-K梯度选择丢弃部分参数更新方向^[18-19], 以及隐私-效用权衡困难, 如压缩后需对保留维度注入更大噪声^[20-21]。还有部分研究采用动态裁剪阈值策略^[22-23], 但在基于LDP的FL中, 由于每个参与者在每次迭代均需对梯度进行扰动以保护隐私, 导致噪声积累加剧, 进一步放大了梯度精度丢失问题。此外, 还有方法采用扰动目标函数而非梯度结果的方式满足避免梯度精度丢失^[24], 由于其直接对目标函数施加扰动, 噪声量固定不受梯度值范围影响可以有效平衡模型性能, 但引入的噪声量级会受维度的增加而增高^[16]。因此, 为了兼顾MCS-FL下模型准确性与隐私性的平衡并解决梯度精度缺失的问题, 本文引入Rényi-DP(RDP), 相较于传统的DP, RDP支持多轮训练聚合而不显著增加隐私预算, 提出了一种基于目标扰动的RDP隐私保护方案, 该方法采用基于泰勒展开扰动的方式, 避免梯度裁剪, 可以有效地提高模型训练的准确度和隐私保护水平。

但遗憾的是现有研究通常假设MCS中各客户端的数据是独立同分布的, 即假设各个客户端的数据来自相同的分布且相互独立^[17-18], 无法有效应用于异构环境。然而MCS是一个典型的异构环境^[25], 各个客户端的数据来源不同, 感知节点的数据分布具有显著差异, 且数据记录之间存在依赖关系。这种数据异构性在全局模型聚合时会导致精度下降。为了优化基础方案存在的问题, 本文使用本地参数与全局参数的Bregman散度计算近端项来更新本地模型, 从而在数据异构性、收敛稳定性和模型性能之间实现更优平衡。

本文主要贡献如下:

1) 首先, 针对DP-SGD过程中梯度精度丢失的问题, 提出了基于目标扰动的RDP基础方案, 先将数据进行降维, 接着对目标函数进行泰勒展开然后进行RDP扰动, 以解决裁剪导致的模型精度降低问题并保护参与者隐私;

2) 针对MCS中非独立同分布(non-Independent and Identically Distributed, non-IID)数据引起的FL模型收敛性下降问题, 通过计算本地参数与全局参数的Bregman散度计算近端项来更新本地模型, 缓解了权重发散所导致的准确率降低问题, 提升了模型准确率;

3) 最后, 通过理论证明了所提算法满足DP, 并在3组数据集上进行了大量实验, 结果表明相比于其他方法, 本文方法在隐私保护和效用优化上有显著提升。

本文结构安排如下: 第2节介绍了该领域的相关工作; 在第3节展示了整体模型架构、模型威胁和设计目标; 第4节详细介绍了提出的方案, 并进行了理论分析; 第5节评估了本文方法的性能; 最后, 进行了总结。

2 相关工作

2.1 隐私增强

近年来,众多学者提出了一系列MCS中的隐私保护方案,目前主要运用的技术为同态加密、多方安全计算和DP,其中DP凭借在分布式框架下可以为每个MCS参与者都提供隐私保护被广泛运用. (ϵ, δ) -DP^[26]机制,通过在严格数学框架中引入可控的概率松弛项 δ ,可以有效地优化隐私-效用的平衡,既保证了DP的强保证特性,又通过放宽约束条件支持高维数据聚合. Zhang等人^[6]提出了一种基于DP的MCS轨迹隐私保护方法,通过聚类轨迹数据提取特征区域并个性化分配隐私预算,生成相似混淆点以保护用户隐私. Li等人^[7]提出了一种隐私保护下的MCS参与者招募方案,支持个性化隐私需求的六边形网格系统中的位置混淆机制扰动用户位置. Xie等人^[27]将DP连续数据发布的思想引入到FL中,并提出了整合随机多重梯度下降与差分隐私技术,提高FL的精度. Nguyen等人^[28]提出了一种隐私保护的无线FL算法,通过联合优化时变DP噪声方差与用户发射功率设计,在无线信道噪声环境下平衡隐私保护与模型效用,并基于学习误差上界最小化优化联邦学习迭代次数.

Rényi^[29]使用Rényi散度扩展了DP的概念,相较于传统的DP可以提供更细粒度的隐私保护,尤其是在多轮训练和数据异质性较强的场景下,能更好地平衡隐私保护与模型性能. Zhou等人^[26]提出了一种基于分布式DP的FL方法,通过安全混洗模型和Rényi散度精确控制隐私损失. Hu等人^[30]提出了Fed-SMP,这是一种新颖的差分私有联邦学习方案,利用稀疏模型扰动提供客户端级DP,同时保持模型准确性.

然而,现有研究仍存在一些不足.一方面,尽管多种隐私保护技术不断涌现,但在实际复杂多变的MCS-FL环境下目前的方案难以做到全面适配.另一方面,在隐私保护与模型性能的平衡上还待改进.

2.2 优化增强

为提高FL的模型准确率,谷歌于2017年引入了FL算法FedAvg^[31],它是开发或改进大多数已经提出的FL算法的基础.但是该模型参数在聚合时会面临泄露的风险. Xie等人^[10]基于前景理论设计了一种MCS激励机制来激励无人机参与FL,即利用基于前景理论的游戏来模拟感知平台和无人机之间的交互,从而得出均衡. Tao等人^[11]设计了层次树和时间序列队列来组织MCS任务和参与者. Abadi等人^[14]设计了一种结合DP的SGD方法,利用动量会计机制动态追踪隐私损耗. FedProx^[32]使用近邻项来稳定模型更新,被提出作为联邦网络异构的解决方案. FedBN^[33]通过将批归一化操作放置在FL的不同层级中,以适应参与方之间的数据差异,从而提高FL的性能和收敛速度. Zhou

等人^[34]提出FL条件可逆神经网络分簇算法,通过全局编码器将客户端数据映射为高斯分布并学习隐特征,实现数据异构场景下的客户端聚类. Zhu等人^[35]在面对non-IID和隐私的挑战,提出了一种基于相关敏感度与迭代发布机制的新型相关DP方案,显著降低噪声并提升隐私保护强度.虽然上述研究在优化效果方面均有所提升,但如何提高MCS-FL的模型准确率仍待改进.此外,现有FL优化方案没有考虑到MCS-FL中的梯度裁剪问题,导致模型精度显著降低.

2.3 相关定义

定义1 (ϵ, δ) -DP^[26]. 对于任意仅相差一条数据的相邻数据集 P_1 和 P_2 ,对于给定的随机算法 Q , $\text{Range}(Q)$ 表示 Q 的取值范围.如果 Q 在给定数据集 P_1 和 P_2 上的输出结果 K , $K \in \text{Range}(Q)$ 满足以下不等式,则称 Q 满足 (ϵ, δ) -DP:

$$\Pr[Q(P_1) \in K] \leq e^\epsilon \Pr[Q(P_2) \in K] + \delta, \quad (1)$$

其中: $\Pr$ 为概率测度符号,表示事件发生概率; ϵ 为隐私预算, $\epsilon \in (0, +\infty)$, ϵ 越小隐私保护越强; δ 表示失败概率.

定义2 高斯机制^[30]. 对于给定 $Q: X \rightarrow \mathbb{R}^d$,高斯机制对输出添加噪声 $\mathcal{N}(0, \sigma^2)$,得到扰动后的结果如下:

$$\mathcal{M}(Q) = Q(X) + \mathcal{N}(0, \sigma^2), \quad (2)$$

且 $\sigma \geq \frac{\Delta Q \sqrt{2 \ln(1.25/\delta)}}{\epsilon}$, 其中: $\mathcal{M}(Q)$ 为高斯机制的输出; $Q(X)$ 为原始查询或函数在数据集 P 的真实输出; $\mathcal{N}(0, \sigma^2)$ 为均值为0、方差为 σ^2 的 d 维高斯分布噪声.

定义3 边级敏感度. 给定 Q , P_1 和 P_2 为任意两个边级相邻数据集,则函数 Q 的 L_2 灵敏度 Δu 如下:

$$\Delta u \triangleq \max_{P_1, P_2 \in P} \|Q(P_1) - Q(P_2)\|_2, \quad (3)$$

其中: $\|Q(P_1) - Q(P_2)\|_2$ 为查询在这两个数据集上的输出之间的灵敏度误差, $\|\cdot\|_2$ 为 L_2 范数.

定义4 Rényi-散度^[30]. 设 M 和 N 为在定义域 r 上的概率分布. 给定定义Rényi-散度为

$$R_h(M \| N) \triangleq \frac{1}{e-1} \log \epsilon \left[\left(\frac{M(x)}{N(x)} \right)^e \right], \quad (4)$$

其中: $M(x)$ 和 $N(x)$ 分别是 M 和 N 在 x 点的密度, e 是散度的阶数,控制对差异的敏感程度.

定义5 Bregman散度^[25]. 给定一个凸函数和定义域内的两个点 x 和 y , Bregman散度 $D_h(x \| y)$ 被定义为函数 h 在点 x 处的值与以点 y 为中心的一阶泰勒近似值在点 x 处的差值,其值可以表示为

$$D_h(x \| y) = h(x) - h(y) - \langle \nabla h(y), x - y \rangle, \quad (5)$$

其中: $h(x)$ 为严格凸函数, $\langle \cdot, \cdot \rangle$ 表示内积, $\nabla h(y)$ 表示函数 h 在点 y 处的梯度.

3 系统模型

3.1 整体模型架构和流程

本模型主要特点是提出联邦边缘协同架构, 模型采用云平台即中央服务器、边缘服务器 (edge server, ES) 和移动终端即参与者的 3 层架构. 该架构可以有效解决 MCS 地理分布广、终端资源受限和计算开销的难点. 中心服务器负责全局模型初始化和最终聚合; ES 负责区域内参与者模型的中间聚合, 以减少中心服务器负载和通信延迟; 移动终端负责本地数据采集、降维、本地模型训练与隐私扰动. 通过云平台, 请求者将 FL 任务外包给一组 N 个参与者, 表示为 $\mathcal{N} = \{1, \dots, i, \dots, N\}$. 边缘节点 EN (edge node), 负责协调平台与参与者之间的局部模型聚合 $\mathcal{M} = \{1, \dots, j, \dots, M\}$. 每个参与者通过移动智能设备收集数据, 并将数据存储在其本地数据集中 $\mathcal{D}_i = \{(X_1, y_1)\}$, 其中: $X_1 \in \mathbb{R}^d$ 为输入的 d 维样本向量, 如图像的像素; y_1 表示为对应的输出, 如图像的标记输出. 本系统以时隙方式运

行, 整个过程分为 t 轮.

FL 的全局优化目标为

$$\min_{\omega \in \mathbb{R}^d} \{F(\omega) = \frac{1}{N} \sum_{i=1}^N F_i(\omega)\}, \quad (6)$$

$$F_i(\omega) = \min_{w_i \in \mathbb{R}^d} \{f_i(w_i) + \alpha D_h(w_i, \omega)\}, \quad (7)$$

其中: ω 为全局模型参数; $F(\omega)$ 是所有客户端本地模型最小正则化损失的平均值; $F_i(\omega)$ 表示第 i 个客户端本地模型损失的正则化最小值; $f_i(w_i)$ 表示第 i 个客户端的正则化更新损失函数; α 表示控制 w_i 与 ω 之间差异的正则化参数; N 为参与的用户总数; D_h 表示 Bregman 散度计算.

在每一轮中, 参与者根据他们采集的数据来训练本地机器学习模型, 流程图见图 2 所示. 每个 ES 可以接收局部模型并进行聚合, 得到一个中间模型 (矩阵). 然后, 平台将这些中间参数模型进行聚合, 得到全局模型, 并利用验证数据集验证模型的准确性. 本文将第 t 轮中的全局模型表示为 $F(\omega_g^t; \cdot)$ 和第 i 个局部模型表示为 $F(\omega_i^t; \cdot)$. 矩阵 ω_g^t 和 ω_i^t 是模型参数, 其中: g 表示全局模型, i 表示第 i 个参与者.




图 2 流程图

Fig. 2 Flowchart

1) 任务请求: 开始时, 任务请求者以一定的报酬通过请求将 FL 任务 (包括数据采集和模型训练) 外包给平台来启动任务. 除了任务内容外, 请求还可以包含一些要求;

2) 初始化: 平台构建初始的全局模型 $F(\omega_g^0; \cdot)$, 并通过 EN 向全体员工公示要求和报酬规则. 其中, 初始时 $t=0$;

3) 数据采集: 每个参与者 i 根据指定的要求收集数据, 并通过 LDP-联邦随机主成分分析 (federated randomized principal component analysis, FRPCA) 对原始数据降维, 然后更新其本地数据集 $\mathcal{D}_i$;

4) 本地训练阶段: 当每个参与者接收到来自云端的全局模型参数后, 通过 Bregman 散度衡量本地模型与全局模型的差异^[34], 将其作为惩罚项更新损失函数. 本地训练模型可以表示为

$$\omega_i^t = \omega_i^{t-1} - \eta_i \nabla (F_i(\omega_g^{t-1}; \mathcal{D}_i)), \quad (8)$$

其中: ω_i^t 是第 i 个客户端在第 t 轮次的模型参数; η_i 为学习率; $\nabla (F_i(\omega_g^{t-1}; \mathcal{D}_i))$ 为全局模型第 $t-1$ 轮的梯度.

5) 隐私增强: 在本地数据上传之前, 对 Bregman 散度更新后的本地模型进行目标函数扰动, 并将扰动后的模型参数上传至云端;

6) 局部聚合: 每个 ES _{j} 接收一组在预定时间内扰

动后的模型参数,然后执行局部聚合获得一个中间参数矩阵 $\tilde{\omega}_j^t, \tilde{\omega}_j^t = \sum_{i \in s_j} \tilde{\omega}_i^t$,其中: s_j 为归属边缘节点 j 的参与者集合; ω_i^t 为第 i 个参与者在第 t 轮上传的扰动后模型参数,表示在第 t 轮将扰动模型参数 ω_i^t 上传到 ES_j ,然后 ES_j 将扰动后的模型参数 $\tilde{\omega}_j^t$ 发送到平台;

7) 全局聚合阶段: 云端接收到所有参与者模型参数,平台对所有中间参数矩阵进行聚合,得到一个全局模型参数矩阵,即 $\omega_g^t = \sum_{j=1}^M \tilde{\omega}_j^t$. 整体聚合后,平台将更新全局模型为 $F(\omega_g^t; \cdot)$,并向所有 EN_j 下发全局模型 $F(\omega_g^{t-1}; \cdot)$,不断重复上述操作直至模型收敛.

3.2 设计目标

在上述FL-MCS系统中,本文的目标是实现一种模型准确率保证的隐私保护机制. 具体来说,本文需要实现以下设计目标:

1) 数据隐私性: 设计一种有效地隐私保护机制以满足DP要求,确保在FL过程中参与者的本地数据不会泄露且可以在多个客户端之间安全共享模型更新;

2) 模型准确率保证: 在向其局部模型注入扰动后全局模型的准确性得到保证.

3.3 威胁模型

与大多数MCS中DP隐私保护相关的现有工作类似^[6-7],本文假设如下:

1) 参与者和任务发布被视为可信的主体,他们将提供正确且可信的数据并遵循方案要求,且不会与服务器勾结;

2) 服务器是不可信的,尽管他们按照协议进行模型训练但也可能会侵犯用户隐私,服务器可能利用其他客户端上传的模型信息来反向推断其本地数据的敏感信息,例如推断出特定用户的偏好或行为模式.

本文主要解决用户端的模型参数隐私保护问题,以满足对用户基于DP的隐私保护要求,防止服务器获取用户敏感信息. 为了防止不可信的边缘服务器获取用户隐私,本文假设威胁服务器实体为 A . 对于任意相邻数据集 D, D' (仅差一条敏感数据),以及输出子集 $O \subseteq \text{Range}(Y)$,本文方案 Y 满足以下概率不等式: $\Pr[Y(D) \in O] \leq e^\epsilon \cdot \Pr[Y(D') \in O] + \delta$,其中 ϵ, δ 为RDP隐私预算参数. 从而确保威胁实体 A 无法以显著概率区分 D 与 D' ,提供严格的隐私保障.

4 面向隐私保护的MCS-FL方法

本节设计了一种基于隐私保护的MCS-FL框架. 首先提出了一种基础方案方法,先采用FPCA对高维数据进行预处理,然后对目标函数泰勒展开,同时在权重系数中添加自适应RDP噪声从而实现隐私保护与模型精度之间的平衡. 同时,为了缓解non-IID数据对全局模型收敛性的影响,采用Bregman散度作为正

则化项以优化本地模型与全局模型的协同训练.

4.1 基础方案

4.1.1 降维

目标扰动算法在处理高维数据或non-IID数据时,各客户端目标函数间存在显著差异,可能导致全局优化方向不一致,进而影响模型的收敛性与准确性^[35],因此降低数据维度具有重要意义. RPCA^[35]是一种用于高维数据的降维方法. 相较于其他降维方法如PCA, isomap和UMAP,它使用较少的存储空间来表示数据的特点,适用于大规模高维数据. 为了缓解MCS数据直接降维后对应维度代表的信息不再一致,导致参与者间本地模型参数的差异性大的问题^[16],本文将RPCA降维后的数据进行LDP扰动后再上传聚合即FRPCA,从而更符合全局一致性. 假设参与者的本地数据集 D_i 的特征部分被表示为矩阵 $M_i' \in \mathbb{R}^{D_i \times p}$,随机矩阵为 $Q, Q \in \mathbb{R}^{(n \times p)}$,其中 p 为维度, $\rho = k + \alpha$, k 为期望的主成分数量, α 为过采样参数. 设第 i 个客户端在某一轮次中的模型参数矩阵 $M' = \{m'_1, m'_2, \dots, m'_i, \dots, m'_n\}$,其中 m'_i 代表第 i 个客户端的模型参数. 本文将FRPCA应用到参数矩阵 M' ,具体表示为 $M' = P_Y(M)$,其中: P_Y 代表RPCA投影操作符; Y 是降低后的维数($Y < p$),其值可以根据具体的客户端数据分布和计算开销进行调整; M 是RPCA投影后得到的降维模型参数矩阵.

4.1.2 基于泰勒展开的RDP目标扰动

为了解决传统方法在对梯度进行裁剪时导致的梯度精度丢失问题,本文采用基于泰勒展开的目标扰动机制. 该机制通过因式分解,将噪声分配到多个因子上,能够减少噪声对模型训练精度的影响,从而提高全局模型的精度^[24].

首先使用降维后的数据集进行深度可分离卷积神经网络(depthwise separable convolution neural network, DS-CNN)的训练. 其包含深度可分离卷积层,全局平均池化层和一个输出层. 由于只有深度卷积和逐点卷积两个隐藏层的操作,模型在保持有效性的同时大大减少了参数量,并选择Adam优化器进行优化,利用ReLU激活函数进行非线性转换.

矩阵数据集将以SGD的方式,设 B 为训练样本, $|B|$ 为随机抽取的样本个数. 隐藏层的映射输出函数由 $r(\tau_i, W)$ 表示, W 为权重矩阵,损失函数 $f(z)$ 采用交叉熵函数, z 为模型输出. 因此,DS-CNN的目标函数 $\mathcal{Y}(B, W)$ 的定义如下:

$$f(z) = - \sum_{j=1}^c y_j \log(z_j), \quad (9)$$

$$\mathcal{Y}(B, W) = \sum_{\tau \in B} f(r(\tau_i, W)), \quad (10)$$

其中: c 为输出类别数目; y_j 为样本真实标签的one-hot编码(若样本属于第 j 类,则 $y_j = 1$,否则为0), z_j 为模

型预测输出的第 j 类概率值; τ_i 为第 i 个样本, 包含输入特征 x_i 和标签 y_i .

接下来将目标函数转换为关于权重 W 的多项式形式, 同时对 $\mathcal{Y}(B, W)$ 泰勒展开, θ 为泰勒展开的中心点, 并保留前 3 项 (其中 $k \in [0, 2]$), 从而获得近似的目标函数 $\bar{\mathcal{Y}}(B, W)$, 即

$$\begin{aligned} \hat{y}(B, W) &= \sum_{\tau_i \in B} \sum_{j=1}^c \sum_{k=0}^z \left[\frac{f^{(k)}(\theta)}{k!} (r(\tau_i, W) - \theta)^k \right] = \\ &= \sum_{\tau_i \in B} \sum_{j=1}^c [f^{(0)}(\theta) + f^{(1)}(\theta)r(\tau_i, W) + \\ &\quad \frac{f^{(2)}(\theta)}{2} r^2(\tau_i, W)] = \\ &= \sum_{\tau_i \in B} [r(\tau_i, W) + \frac{c}{2} r^2(\tau_i, W)], \quad (11) \end{aligned}$$

$\bar{\mathcal{Y}}(B, w)$ 可表示为如下关于权重 W 的多项式形式:

$$\bar{\mathcal{Y}}(B, W) = \sum_{j=1}^J \sum_{\phi \in \Pi_j} \sum_{\tau_i \in B} b_{\phi\tau_i} \phi(W), \quad (12)$$

$$\Pi_j = \{W_1^{c_1} W_2^{c_2} \cdots W_d^{c_d} \mid \sum_{l=1}^d c_l = j\}, \quad (13)$$

其中: $b_{\phi\tau_i}$ 为某个单项式 ϕ 对应的系数, 由泰勒展开计算得到; Π_j 表示关于 W 且次数为 j 的单项式 ϕ 的集合; c_l 为权重矩阵 W 中第 l 个参数 W_l 的幂次.

$\bar{\mathcal{Y}}(B, W)$ 的最高次项来自 $r^2(\tau_i, W)$, 所以 W 单项式的最高次数为 4, 即 $J = 4$.

然后使用高斯机制对目标函数 $\bar{\mathcal{Y}}(B, W)$ 中梯度进行扰动. 现有方法通常对样本添加固定的高斯噪声, 无法充分应对不同场景和需求的变化. 因此, 本节提出一种自适应衰减噪声机制算法, 从而可以对每个迭代的样本自适应添加高斯噪声.

具体而言, 本文设计了包含 3 种机制的高斯噪声动态混合调整策略, 分别为基于时间、指数和步长的调整, 来动态调整高斯噪声尺度, 实现高精度度与安全性之间的平衡, 如式(14)所示:

$$\sigma_n = \begin{cases} \sigma_0 \cdot e^{-\lambda_1 n}, & \text{如果 } n < t_1, \\ \sigma_0 \cdot \frac{1}{1 + \lambda_2 n}, & \text{如果 } t_1 \leq n < t_k, \\ \sigma_0 \cdot \lambda_3^{\frac{n}{n^*}}, & \text{如果 } n \geq t_k, \end{cases} \quad (14)$$

其中: $\lambda_1, \lambda_2, \lambda_3 \in (0, 1)$ 为衰减率; σ_0 为初始噪声尺度; t_1 和 t_k 分别是衰减轮次的开始和结束; n 和 n^* 分别是当前衰减迭代的次数和整个衰减周期.

第 1 阶段为指数调整阶段, 为快速调整的阶段. 指数调整可以快速减少噪声的规模, 对近期数据点赋予更大的权重, 适用于对初始阶段快速收敛. 在这一阶段, 噪声标准差 σ_n 以指数衰减的方式随着迭代次数 n 增加而减少;

第 2 阶段为时间调整阶段, 为平缓调整的阶段. 在这一阶段噪声收敛较为平缓, 基于时间的调整机制有

助于平衡噪声和数据效用. 随着迭代次数 n 增加, 噪声标准差 σ_n 以时间相关的非线性函数逐步减小, 减少速度较慢;

第 3 阶段为基于步长的调整机制, 为稳定的阶段, 模型趋于收敛, 噪声调整较慢以维持性能和稳定性. 在这一阶段, 噪声标准差 σ_n 根据步长变化调整, 噪声的减小速度与 n 呈反比关系.

4.2 Bregman 优化

MCS 中的参与者数据通常是 non-IID 的, 这些异构数据在进行全局训练时会导致模型性能下降^[25]. 为此, 本文使用 Bregman 散度来衡量本地参数与全局参数之间的差异, 并将其作为正则化项纳入损失函数中, 以减小本地模型与全局模型之间的差距, 从而提升模型的整体性能.

在 non-IID 数据下, FL 的全局最优解与各个局部最优解之间的距离并不相等, 平均后的模型会偏离全局最优解, 导致全局模型无法收敛到其真正的全局最优. Bregman 散度可以通过对全局模型和局部模型的差异进行度量, 从而促使全局模型重新收敛到全局最优解. Bregman 散度相比欧氏距离可以适应不同的数据分布和先验知识更好地区分不同的向量.

Bregman 散度作为正则化项更新各客户端的损失函数为

$$f_i(\omega_i) = E[f(\omega; D_i)], \quad (15)$$

其中: ω 为全局模型参数; $f_i(\omega_i)$ 表示第 i 个客户端的正则化更新损失函数; ω_i 表示本地模型参数. FL 优化问题转化为

$$\min_{\omega \in \mathbb{R}^d} \{F(\omega) = \frac{1}{N} \sum_{i=1}^N F_i(\omega)\}, \quad (16)$$

$$F_i(\omega) = \min_{\omega_i \in \mathbb{R}^d} \{f_i(\omega_i) + \alpha D_h(\omega_i, \omega)\}, \quad (17)$$

其中: d 为模型参数 ω 的维度; 式(16)是全局优化目标, 它是所有客户端的局部损失函数的平均值, 其中每个客户端的局部损失函数由式(17)定义; α 表示控制 ω_i 与 ω 之间差异的正则化参数; D_h 表示 Bregman 散度计算结果.

式(17)是局部优化问题, 它是在每个客户端上最小化一个包含两项的函数, 前一项代表客户端的经验损失函数, 第 2 项则是一个正则化项, 它是用 Bregman 散度来衡量客户端的本地模型参数与全局模型参数之间的差异, 以此减小模型异构, 提高模型准确率.

为了求解式(16), 首先通过损失函数采样训练数据 D_i , 如式(18)所示:

$$E[\nabla f_i(\omega_i, D_i)] = \nabla f_i(\omega_i), \quad (18)$$

其中 $\nabla f_i(\omega_i, D_i)$ 表示客户端 i 基于当前模型参数 ω_i 和本地数据集 D_i 计算的随机梯度.

接着, 计算 Bregman 散度, 选择波尔兹曼香农熵

$q(x) = x_j \ln \sum (x_j) - x_j$, $x = (x_j)_{1 \leq j \leq J}$, $y = (y_t)_{1 \leq t \leq T}$ 作为凸函数, 因而与 $q(x)$ 相关的Bregman距离定义为

$$D_q(x, y) = \sum_{j=1}^J [x_j \ln \frac{x_j}{y_j} - x_j + y_j], \quad (19)$$

$$x \geq 0, y > 0.$$

本地与全局模型的梯度期望可以定义本地模型和全局模型之间的Bregman散度为

$$D_q(\omega_i, \omega) = \sum_{j=1}^d (\omega_i^j \ln \frac{\omega_i^j}{\omega^j} - \omega_i^j + \omega^j), \quad (20)$$

其中 ω_i 和 ω 都是 d 维向量, 但本地模型和全局模型无法直接求得 Bregman 散度, 因为它们包含负数. 本文采用 Softmax 函数使其满足概率分布, 再求取本地模型与全局模型的差异. 通过 Bregman 散度改进损失函数, 它可以减少 FL 客户模型训练过程中模型异质性引起的收敛性下降的影响.

最后, 更新客户端模型参数, 通过 Bregman 散度作为正则化项, 更新本地损失函数, 然后使用梯度下降法优化本地模型参数.

$$g_i(\omega_{i,r}^t, \omega_t) = f_i(\omega_{i,r}^t) + a D_h(\omega_{i,r}^t, \omega_t), \quad (21)$$

$$\omega_{i,r+1}^t = \omega_{i,r}^t - \eta \nabla g_i, \quad (22)$$

其中: g_i 为第 i 个客户端在本地迭代中的复合损失函数, 结合了原始损失和正则化项; a 表示控制 ω_i 与 ω 之间差异的正则化参数; ∇g_i 为复合损失函数 g_i 对本地参数 $\omega_{i,r}^t$ 的梯度.

本节在本地损失函数中引入 $D_h(\omega_i, \omega)$, 约束客户端模型与全局模型的偏离, 借鉴了 FedProx^[32] 的近端项思想, 其收敛性已在异构数据场景下被广泛验证. 后续实验表明, 本文方法的收敛速度优于 FedProx.

4.3 隐私分析

本节对所述方法的隐私性进行分析.

定义 6 目标函数敏感度. 设相邻数据集 D 和 D' 仅相差一个样本, 目标函数 $\tilde{\mathcal{Y}}(B, W)$ 的 l_2 敏感度为

$$\Delta s = \max \|\tilde{\mathcal{Y}}(D, W) - \tilde{\mathcal{Y}}(D', W)\|_2. \quad (23)$$

定理 1 单轮 Rényi 保证. 单轮训练中, 目标扰动机制满足 (α, ε) -RDP, 其中

$$\varepsilon(\alpha) = \frac{\alpha \Delta s^2}{2\sigma^2}. \quad (24)$$

证 对任意输出 Rényi 散度满足

$$R_\alpha(\mathcal{M}(D) \parallel \mathcal{M}(D')) \leq \frac{\alpha \Delta s^2}{2\sigma^2}. \quad (25)$$

证毕.

定理 2 多轮隐私预算累积. 经过 t 轮训练, 总隐私预算为

$$\varepsilon_{\text{total}}(\alpha) = t \frac{\alpha \Delta s^2}{2\sigma^2}. \quad (26)$$

证 通过动态噪声调整机制调整衰减噪声尺度 σ_t , 使总隐私预算满足

$$\sum_{t=1}^T \frac{\alpha \Delta s^2}{2\sigma_t^2} \leq \varepsilon_{\text{target}}, \quad (27)$$

通过设定 $\sigma_t = \frac{\sigma_0}{\sqrt{t}}$, 可保证总隐私预算 $\varepsilon_{\text{total}} = O(\log T)$. 证毕.

5 实验

本节通过多组实验对本文方法进行评估, 内容安排如下: 第 5.1 节介绍实验设置; 第 5.2 节讨论对比方法; 第 5.3 节介绍了实验实现过程和结果.

5.1 实验设置

运行硬件配置是 Intel(R) Core(TM) i7-10750H CPU, GTX2060 GPU, 16 GB RAM, 实验操作系统是 Windows 10.

为验证所提方法的有效性, 本研究在 MNIST^[36], CIFAR-10^[37] 和 CIFAR-100^[37] 这 3 个数据集上进行了对比实验和方案运行. 这些数据集的数据特征具体如下: MNIST 是手写字符识别数据集, 数据集包含 6 万个训练样本和 1 万个测试样本, 全部为手写数字图片, 每个样本为 28×28 的灰度图像, 其笔画方向和粗细变化特征显著, 背景简单统一; CIFAR-10 数据集包含 5 万个训练样本和 1 万个测试样本, 涵盖了 10 个类别的 32×32 像素彩色图片, 每个类别包含 6000 张图像, 具有丰富的物体形态和复杂背景特征; CIFAR-100 与 CIFAR-10 具有相同的样本, 但是进一步细分为 100 个类别, 可以为模型捕捉更精细的特征差异.

为了模拟 MCS 中的异构环境, 本文采用了狄利克雷分布策略, 实现对各客户端随机分配不同大小的本地数据集和标签数量, 确保每个客户端数据具有较强的数据统计异质性. 通过调整 α 值模拟不同异构程度以随机分配不同规模类别的数据子集至客户端. $\alpha \in \{0.05, 0.1, 0.5\}$, α 与异构程度成反比.

本文设置用户数目为 100, 实验数据均为测试数据, 训练网络均为卷积神经网络. 此外, 为实验设置客户端本地训练次数为 5 次, 学习率 $\eta = 0.01$, 噪声衰减参数 $\lambda_1 = 0.1$, $\lambda_2 = 0.05$, $\lambda_3 = 0.01$.

5.2 对比方法

为了有效评估本文方法的有效性, 本文将其与以下代表性方法进行了对比实验.

1) SecProbe^[8]: 采用固定噪声注入, 每个参与方在上传本地模型参数之前, 通过添加噪声或扰动保护个体数据的隐私; 2) ATBA^[11]: 采用基于分层分离树的 MCS 新型隐私保护机制; 3) RDP-SGD^[26]: 基于 RDP 的梯度扰动; 4) FedAvg^[31]: 直接上传原始梯度并进行平均聚合, 是一种不对数据进行隐私保护的 FL 算法. 在本文实验中 FedAvg 为基准线; 5) FedProx^[32]: 引入


近端项优化异构数据; 6) FedBN^[33]: 采用客户端批归一化缓解数据分布差异的FL方法。

5.3 实验评估


5.3.1 测试精度分析

本节基于不同数据集的准确率, 评估各方法的模型收敛性能, 介绍了在 $\varepsilon = 4$ 和 $\varepsilon = 8$ 时不同数据集下模型在不同训练轮数下的准确率变化, 实验结果如图3–4所示。由图3(a)和图4(a)可知, 在MNIST数据集上, 各方法在训练初期, 即轮次 <75 轮时准确率较低, 但随着训练轮次的增加, 准确率逐渐提升。FedAvg方法在训练后期准确率变化趋于平缓, 收敛速度较慢。FedBN由于未引入隐私噪声, 在早期训练阶段展现出较高的准确率, 但无法提供隐私保护。本文所提方法在整个训练过程中准确率最高, 在 $\varepsilon = 4$ 下, 最终收敛准确率达到82.1%, 相比于次优的SecProbe高出3.8%, 显示了更优的隐私–效用权衡能力。在 $\varepsilon = 8$ 下, 如图4(a)所示, 由于隐私预算更大, 所有方法的最终准确率均有所提升。其中, 本文所提方法收敛精度为83.5%, 依然优于其他方法, 验证了其在增强隐私保护的同时, 仍能保持较高训练性能的优势。


由图3(b)和图4(b)可知, 在CIFAR-10数据集上, 任务的复杂度相较MNIST更高, 但整体训练趋势相似。从图3(b)和图4(b)可见, 训练初期, 所有方法的准确率均较低, 但随着训练的进行, 准确率快速上升。在 $\varepsilon = 4$ 时, 本文所提方法最终收敛准确率达到80.7%, 明显优于其他方法。在 $\varepsilon = 8$ 时, 本文所提方法进一步优化, 最终收敛精度达到85.7%, 依然保持最优性能。



(a) $\varepsilon = 4$ MNIST




(b) $\varepsilon = 4$ CIFAR-10




(c) $\varepsilon = 4$ CIFAR-100

图 3 $\varepsilon = 4$ 下不同数据集的准确率对比


Fig. 3 Accuracy comparison across different datasets at $\varepsilon = 4$



(a) $\varepsilon = 8$ MNIST



(b) $\varepsilon = 8$ CIFAR-10



(c) $\varepsilon = 8$ CIFAR-100

图 4 $\varepsilon = 8$ 下不同数据集的准确率对比

Fig. 4 Accuracy comparison across different datasets at $\varepsilon = 8$

由图3(c)和图4(c)可知, 在CIFAR-100数据集上, 由于类别数量更多各方法的整体准确率比CIFAR-10

略低. 训练初期各方法的准确率均较低, 但随着训练轮次增加模型精度稳步提升. 在 $\varepsilon = 4$ 下, 本文所提方法在收敛时达到77.9%的最高准确率, 相比SecProbe, FedProx, FedBN和FedAvg提高了2.8%, 5.8%, 11%和15%. 在 $\varepsilon = 8$ 下, 本文所提方法最终收敛准确率为82.4%, 相比FedBN, SecProbe, FedProx和FedAvg提高了2.4%, 4.4%, 2.7%和9.4%, 表现出更好的隐私-效用平衡能力.

综合图3-4的实验结果可以发现, 本文所提方法在所有数据集上均表现最佳, 在隐私保护和准确率之间取得了最优的权衡. 但在训练后期还是会出现精度的波动, 这主要由两个因素导致: 首先, DP的噪声注入虽然采用动态衰减机制, 但为满足总隐私预算, 噪声不能无限减小形成持续扰动, 后期模型接近收敛时残余噪声会导致精度产生浮动; 其次, non-IID数据分布导致客户端梯度方向发散, 即使Bregman散度约束了参数差异, 但不同客户端的特征分布仍存在偏移, 导致后期改善有限. 本文所提方法已将波动幅度降低, 但仍属隐私保护FL的固有现象. 此外, 更高的 ε 值使得所有方法的准确率普遍提升. 即使CIFAR-100类别较多, 但本文所提方法依然在该数据集上取得最优的收敛结果. 因此, 本文所提方法能够在保证数据隐私的同时, 有效提升模型的准确率和收敛速度, 在不同数据集和隐私预算下均展现出优越的性能.

5.3.2 异构数据下的收敛性分析

为验证本文方法在异构数据环境下的收敛性能, 本实验基于MNIST数据集, 在non-IID条件下对比了本文方法与FedBN, FedProx, SecProbe及FedAvg的收敛表现. 实验中通过狄利克雷分布 α 模拟数据异构性, $\alpha \in \{0.05, 0.1, 0.5\}$, 并记录模型损失值随训练轮次的变化趋势. 表1对比了不同 α 值下的收敛轮次.

表1 不同异构程度下的收敛轮次对比

Table 1 Convergence round comparison across varying heterogeneity levels

方法	$\alpha = 0.05$	$\alpha = 0.1$	$\alpha = 0.5$
OURS	202	156	100
FedBN	257	206	112
FedProx	292	218	130
SecProbe	310	250	162
FedAvg	325	200	170

由实验结果可见, 随着 α 值的减小, 即数据异构性增强, 所有方法的收敛迭代次数均显著增加. 当 $\alpha = 0.05$, 即强异构时, 本文所提方法仅需202轮达到收敛, 相较于FedProx和SecProbe分别减少了30.8%和34.8%, 相比FedBN和FedAvg也分别减少了21.4%和

37.8%, 表明本方法在高度异构数据环境下的收敛速度优势明显, 证明了Bregman散度通过约束本地模型与全局模型的优化方向, 有效缓解了数据分布偏移问题, 从而提高了模型在非独立同分布数据下的适应性. 当 $\alpha = 0.5$ 时, 各方法的收敛轮次差距缩小, 但OURS仍能保持最优收敛性能, 相比FedBN, FedProx, SecProbe和FedAvg分别减少了10.7%, 23.1%, 38.3%和41.2%的训练轮次, 进一步验证了本方法在不同异构环境下的稳定性和高效性.

5.3.3 收敛性能对比

为评估本文方法的收敛性能, 本文在MNIST, CIFAR-10和CIFAR-100数据集上, 对比了OURS, FedBN, FedProx, SecProbe和FedAvg方法的收敛迭代次数和训练时间.

表2为各方法在不同数据集下的收敛迭代次数和训练时间对比. 收敛迭代次数是衡量模型收敛速度的重要指标. 由表2可见, 本文所提方法在MNIST, CIFAR-10和CIFAR-100数据集上的收敛迭代次数相比FedProx分别减少了28.4%, 24.2%和14.3%, 相比其他方法显著减少, 表明本文方法能够在更少的训练轮次内达到收敛. 原因在于本文采用了Bregman散度优化, 通过约束本地模型与全局模型的优化方向, 有效缓解数据异构性对收敛过程的影响, 从而提升了训练效率.

表2 不同方法收敛性能对比

Table 2 Comparison of Convergence Performance Among Different Methods

数据集	方法	收敛迭代次数	训练时间/s
MNIST	OURS	156	3978.2
	FedBN	206	4232.9
	FedProx	218	4336.2
	SecProbe	250	4341.4
	FedAvg	200	4257.9
CIFAR-10	OURS	204	4013.4
	FedBN	253	4373.3
	FedProx	269	4415.6
	SecProbe	298	4526.4
	FedAvg	228	4209.3
CIFAR-100	OURS	233	4770.3
	FedBN	248	4873.3
	FedProx	272	5262.2
	SecProbe	283	5410.5
	FedAvg	257	4795.1


在训练时间方面, 本文所提方法在MNIST和CIFAR-10数据集上的训练时间相较于FedBN分别降低了6.0%和8.2%, 相较于FedProx分别降低了8.3%和

9.1%, 表明本文方法在提高收敛速度的同时, 减少了计算负担, 提高了整体训练效率. 在CIFAR-100数据集上, 本文所提方法的训练时间低于其他方法, 说明在面对更复杂的数据集时本文所提方案仍能保持较优的计算效率.


本文方法的收敛性能优势主要归因于以下两点优化措施: 一方面, 本文提出的RDP目标扰动方法避免了传统DP-SGD梯度裁剪所带来的梯度精度损失, 使得模型在隐私保护的同时保持较高的学习效率; 另一方面, 引入Bregman散度优化, 以减少数据异构性对模型收敛的影响, 进一步提升模型收敛速度.

5.3.4 隐私性分析


为了验证本文方法在平衡隐私性与效用性的方面的表现, 在MNIST, CIFAR-10和CIFAR-100数据集上将本文方法与SecProbe, ATBA和RDP-SGD方法进行对比, 观察不同隐私预算 ϵ 变化下训练模型的准确性. 在本实验中, 对各隐私方法设置了从1~10的隐私预算, 实验结果如图5所示. 实验结果表明, 随着隐私预算 ϵ 的增加, 所有方法的噪声注入量相应减少, 从而模型准确率普遍提升. 在MNIST数据集中, 本文方法在所有隐私预算范围内均表现最佳. 在图5(a) MNIST中, 当 $\epsilon = 1$ 时, 本文所提方法准确率为36.2%, 显著高于SecProbe, ATBA和RDP-SGD的, 得益于动态噪声调整策略能减少早期训练干扰. 随着 ϵ 增大, 所有方法准确率提升, 但本文所提方法优于其他方法, 验证了目标扰动机制对梯度精度的保护效果.



(a) MNIST



(a) CIFAR 10



(c) CIFAR 100

图 5 不同隐私预算 ϵ 下准确率的变化

Fig. 5 Accuracy variation under different privacy budgets ϵ

在CIFAR-10数据集中, 本文方法的准确率曲线同样高于其他方法, 且在 $\epsilon = 4$ 时已达到80%, 而SecProbe, ATBA和RDP-SGD的准确率分别为70.5%, 60.3%和59.9%, 表明本文方法在中等隐私预算时具备更好的隐私-效用权衡能力.

在CIFAR-100数据集中, 由于数据复杂度较高, 各方法在低隐私预算下的准确率略低, 但本文方法仍然在整个隐私预算范围内最优.

综上所述, 本文方法在整个隐私预算范围内均展现出较高的准确性, 相较于SecProbe, ATBA和RDP-SGD, 在同等隐私预算条件下能有效减少精度损失. 表明本文方法在保证数据隐私的同时, 能够更优地维持模型的训练效能.

5.3.5 消融实验

为了验证各个组件的有效性, 本节以MNIST数据集为例进行消融实验, 实验中数据维度分别设置为原始数据的 p 倍, $p = 2, 4, 6$, 参与者数量为100. 实验结果如图6所示, 结果表明每个组件的引入都提升了实验的性能.

在此, 将本文提出的方法(OURS)作为所有方案的基准. 具体实验设置如下:

1) OURS-R: 在OURS基础上, 将FRPCA算法改为在本地执行RPCA算法, 该算法使用本地拉普拉斯机制对参与者数据进行降维, 旨在验证FRPCA对数据维度降低的有效性;

2) OURS-B: 在OURS-R基础上, 不使用Bregman全局优化, 旨在验证Bregman方案在non-IID场景下的有效性;

3) OURS-F: 在OURS-B基础上, 直接使用高斯机制而不采用基础方案, 旨在验证基础方案的有效性.

实验结果表明, 所添加的各个组件均对实验准确率有所提升, 其中本文方案表现出了最佳的实验效果.

从OURS-F到OURS-B,进行了含隐私保护的目标函数上传模型准确率在提升,表明基于RDP的目标扰动机制能够提升模型性能。从OURS-B到OURS-R,引入了Bregman散度,模型准确率的提升验证了Bregman方案能够促进全局模型收敛到最优解。从OURS-R到OURS,引入了降维机制,模型准确率在提升表明当维度上升时使用FRPCA能有效降维,它有效地剔除了高维特征中的冗余信息。




图6 消融实验

Fig. 6 Ablation analysis

6 总结

综上所述,本文针对FL-MCS场景构建了基于异构数据和目标扰动的自适应RDP隐私保护方法。在方法设计上,首先,提出新的基础方案。该方案先将数据进行降维,随后将经过RDP扰动后的目标函数代替梯度,避免梯度精度丢失的同时保护数据隐私。然后,引

入Bregman散度作为正则化项更新损失函数,通过减少模型间的异构性,从而提升模型的准确性。为验证该方法的有效性,本研究在异构环境下进行了一系列对比实验,实验结果表明,相较于现有的相关方法,本文所提算法在模型收敛性等方面均呈现出显著的提升。在未来的研究中,笔者将继续优化隐私配置,减少计算开销,实现不同数据分布下的自适应噪声注入,以及开发动态客户端选择策略,以优化异构环境下的训练效率等。

参考文献:

- [1] JIANG Weijin, LÜ Sijian, CHEN Xiaohong. Participant selection optimization model for mobile crowds in crowdsensing. *Control Theory & Applications*, 2022, 39(2): 343 – 351.
(蒋伟进, 吕斯健, 陈晓红. 群智感知中面向移动群体的参与者选择优化模型. 控制理论与应用, 2022, 39(2): 343 – 351.)
- [2] DONG X, ZHANG W, ZHANG Y, et al. Optimizing task location privacy in mobile crowdsensing systems. *IEEE Transactions on Industrial Informatics*, 2021, 18(4): 2762 – 2772.
- [3] XU Y, XIAO M, WU J, et al. A personalized privacy preserving mechanism for crowdsourced federated learning. *IEEE Transactions on Mobile Computing*, 2023, 23(2): 1568 – 1585.
- [4] NING Baoling, LI Wenbo, BI Qiang. A distributed intelligent operation and maintenance framework for autonomous unmanned systems with privacy protection. *Control Theory & Applications*, 2024, 41(8): 1351 – 1360.
(宁宝玲, 李文博, 毕强. 支持隐私保护的自主无人系统分布式智能运维框架. 控制理论与应用, 2024, 41(8): 1351 – 1360.)
- [5] LIU Yanhua, FANG Wenyu, GUO Wenzhong, et al. A DDoS attack detection model in SDN environment based on federated incremental learning. *Chinese Journal of Computers*, 2024, 47(12): 2852 – 2866.
(刘延华, 方文昱, 郭文忠. 基于联邦增量学习的SDN环境下DDoS攻击检测模型. 计算机学报, 2024, 47(12): 2852 – 2866.)
- [6] ZHANG Q, WANG T, TAO Y, et al. Trajectory privacy protection method based on differential privacy in crowdsensing. *IEEE Transactions on Services Computing*, 2024, 17(6): 4423 – 4435.
- [7] LI L, SHI D, ZHANG X, et al. Privacy preserving participant recruitment for coverage maximization in location aware mobile crowdsensing. *IEEE Transactions on Mobile Computing*, 2022, 21(9): 3250 – 3262.
- [8] ZHAO L, WANG Q, ZOU Q, et al. Privacy-preserving collaborative deep learning with unreliable participants. *IEEE Transactions on Information Forensics and Security*, 2025, 20: 129 – 144.
- [9] ZHOU Yousheng, GAO Jingkun, ZUO Xiangjian, et al. Secure federated learning scheme based on adaptive byzantine defense. *Journal on Communications*, 2024, 45(8): 166 – 179.
(周由胜, 高璟琨, 左祥建, 等. 基于自适应拜占庭防御的安全联邦学习方案. 通信学报, 2024, 45(8): 166 – 179.)
- [10] XIE L, SU Z, WANG Y, et al. A practical federated learning framework with truthful incentive in UAV-assisted crowdsensing. *IEEE Transactions on Information Forensics & Security*, 2025, 20: 129 – 144.
- [11] TAO Q, TONG Y, ZHOU Z, et al. Differentially private online task assignment in spatial crowdsourcing: A tree-based approach. *The 36th International Conference on Data Engineering*. Dallas: IEEE, 2020: 517 – 528.
- [12] WANG H, WANG E, YANG Y, et al. Privacy-preserving online task assignment in spatial crowdsourcing: A graph-based approach. *The Conference on Computer Communications*. London: IEEE, 2022: 570 – 579.

- [13] SORIA-COMAS J, DOMINGO-FERRER J, SÁNCHEZ D, et al. Individual differential privacy: A utility-preserving formulation of differential privacy guarantees. *IEEE Transactions on Information Forensics & Security*, 2017, 12(6): 1418 – 1429.
- [14] ABADI M, CHU A, GOODFELLOW I. Privacy-preserving online task assignment in spatial crowdsourcing: A graph-based approach. *The Conference on Computer Communications*. London: IEEE, 2022: 570 – 579.
- [15] QIN W, LUO X, ZHOU M. Adaptively-accelerated parallel stochastic gradient descent for high-dimensional and incomplete data representation learning. *IEEE Transactions on Big Data*, 10(1): 92 – 107.
- [16] ZHAO L, WANG Q, ZOU Q, et al. Privacy-preserving collaborative deep learning with unreliable participants. *IEEE Transactions on Information Forensics & Security*, 2019, 15: 1486 – 1500.
- [17] PUSTOZEROVA A, BAUMBACH J, MAYER R. Differentially private federated learning: privacy and utility analysis of output perturbation and DP-SGD. *The International Conference on Big Data*. Sorrento: IEEE, 2023: 1486 – 1500.
- [18] GUAN Y, LIU X, NIU J, et al. FedTC: Enabling communication-efficient federated learning via transform coding. *INFOCOM Conference on Computer Communications*. Vancouver: IEEE, 2024: 821 – 830.
- [19] RUAN M, YAN G, XIAO Y, et al. Adaptive Top- K in SGD for communication-efficient distributed learning in multi-robot collaboration. *IEEE Journal of Selected Topics in Signal Processing*, 2024, 18(3): 487 – 501.
- [20] GU B, XU A, HUO Z, et al. Privacy-preserving asynchronous vertical federated learning algorithms for multiparty collaborative learning. *IEEE Transactions on Neural Networks & Learning Systems*, 2021, 33(11): 6103 – 6115.
- [21] GUAN Y, LIU X, REN T, et al. FedMDC: Enabling communication-efficient federated learning over packet lossy networks via multiple description coding. *The International Conference on Multimedia and Expo*. Niigata: IEEE, 2024, 7: 1 – 7.
- [22] SUN X, YUAN Z, KONG X, et al. Communication-efficient and privacy-preserving aggregation in federated learning with adaptability. *IEEE Internet of Things Journal*, 2024, 11(15): 26430 – 26443.
- [23] ANDREW G, THAKKAR O, MCMAHAN B, et al. Differentially private learning with adaptive clipping. *Proceedings of the 35th Conference on Neural Information Processing Systems (NeurIPS)*. Montreal: IEEE, 2021, 34: 17455 – 17466.
- [24] CAO Shixiang, CHEN Chaomeng, TANG Peng, et al. Federated learning algorithm with differential privacy based on function mechanism. *Journal of Computer Science & Technology*, 2023, 46(10): 2178 – 2195.
(曹世翔, 陈超梦, 唐朋, 等. 基于函数机制的差分隐私联邦学习算法. 计算机学报, 2023, 46(10): 2178 – 2195.)
- [25] ZHANG Y, CHEN C L P. Secure heterogeneous data deduplication via fog-assisted mobile crowdsensing in 5G-Enabled IIoT. *IEEE Transactions on Industrial Informatics*, 2022, 18(4): 2849 – 2857.
- [26] ZHOU H, KONG. Distributed differential privacy for federated learning: A privacy-enhancing approach. *The International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC)*. Xiamen: IEEE, 2024, 3: 969 – 972.
- [27] XIE R, LI C, ZHOU X, et al. Differentially private federated learning for multitask objective recognition. *IEEE Transactions on Industrial Informatics*, 2024, 20(5): 7269 – 7281.
- [28] NGUYEN D Q, KIM T. Time-varying noise perturbation and power control for differential-privacy-preserving wireless federated learning. *The 57th Asilomar Conference on Signals, Systems, & Computers*. Pacific Grove: IEEE, 2023: 656 – 660.
- [29] WANG Kun, WANG Yong, LIU Jinyuan, et al. Graph convolutional collaborative filtering recommendation algorithm based on Rényi differential privacy. *Journal of Software*, 2025, 36(3): 1202 – 1217.
(王锬, 王永, 刘金源, 等. 基于Rényi差分隐私的图卷积协同过滤推荐算法. 软件学报, 2025, 36(3): 1202 – 1217.)
- [30] HU R, GUO Y, GONG Y. Federated learning with sparsified model perturbation: Improving accuracy under client-level differential privacy. *IEEE Transactions on Mobile Computing*, 2024, 23(8): 8242 – 8255.
- [31] BRENDAN MEMAHAN H, EIDER MOORE, DANIEL RAMAGE, et al. Communication-efficient learning of deep networks from decentralized data. *The 20th International Conference on Artificial Intelligence & Statistics*, 2017, 54: 1273 – 1282.
- [32] LI T, SAHU A K, ZAHEER M, et al. Federated optimization in heterogeneous networks. *Proceedings of Machine Learning & Systems*, 2020, 2: 429 – 450.
- [33] PENG Z, SONG Y, WANG Q, et al. FedBN: A communication-efficient federated learning strategy based on blockchain. *The 27th International Conference on Computer Supported Cooperative Work in Design (CSCWD)*. Tianjin: IEEE, 2024: 754 – 759.
- [34] ZHOU Y, SHI M, TIAN Y, et al. Federated CINN clustering for accurate clustered federated learning. *IEEE International Conference on Acoustics, Speech & Signal Processing (ICASSP)*. Seoul: IEEE, 2024: 5590 – 5594.
- [35] ZHU T, XIONG P, LI G, et al. Correlated differential privacy: Hiding information in non-IID data set. *IEEE Transactions on Information Forensics & Security*, 2015, 10, 2: 229 – 242.
- [36] LECUN Y, CORTES C, BURGESS C J C. The MNIST database of handwritten digits. <http://yann.lecun.com/exdb/mnist/>.
- [37] KRIZHEVSKY A, NAIR V, HINTON G. CIFAR-10 and CIFAR-100 datasets. <http://www.cs.toronto.edu/kriz/cifar.htm>.

作者简介:

蒋伟进 教授, 目前研究方向为群智感知、边缘计算、社会计算, E-mail: jwjnudt@163.com;

王海娟 博士研究生, 目前研究方向为大模型、群智感知、差分隐私, E-mail: 2502560411@qq.com;

李一骁 博士研究生, 目前研究方向为隐私保护、大模型, E-mail: request_li@163.com;

蒋意蓉 博士研究生, 目前研究方向为大模型、智慧音乐, E-mail: 307553803@qq.com.